ĐẠI HỌC KINH TẾ QUỐC DÂN

BÁO CÁO HỌC PHẦN ĐỀ ÁN

TÊN ĐỀ TÀI

Nghiên cứu và xây dựng hệ thống kiểm chứng độ tin cậy tin tức tiếng Việt dựa trên mô hình học sâu và kiểm chứng nguồn tin thời gian thực

Sinh viên thực hiện: Lê Minh Tuấn

Mã Sinh viên: 11236225

Giảng viên hướng dẫn: ThS. Trần Thị Mỹ Diệp

Hà Nội, 2026

MỤC LỤC

MỤC LỤC 2
MỞ ĐẦU 5
CHƯƠNG I: GIỚI THIỆU 6
1.1. Lý do chọn đề tài 6
1.2. Mục tiêu nghiên cứu 6
1.3. Phạm vi nghiên cứu 7
1.4. Đối tượng nghiên cứu 7
1.5. Ý nghĩa khoa học và thực tiễn 8
1.6. Tổng quan các nghiên cứu trước đây 9
1.6.1. Các nghiên cứu về nhận diện tin giả dựa trên học máy và học sâu 9
1.6.2. Các nghiên cứu đặc thù cho ngôn ngữ Tiếng Việt 9
1.6.3. Khoảng trống nghiên cứu 10
CHƯƠNG II: CƠ SỞ LÝ THUYẾT 12
2.1. Tin giả và thông tin sai lệch 12
2.1.1. Khái niệm và Phân loại 12
2.1.2. Các hình thức biểu hiện phổ biến của tin giả 12
2.1.3. Hệ lụy của tin giả đối với xã hội 12
2.2. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) 13
2.2.1. Khái niệm cơ bản 13
2.2.2. Các kỹ thuật tiền xử lý văn bản tiếng Việt 13
2.2.3. Biểu diễn văn bản dưới dạng Vector (Word Embedding) 13
2.2.4. Phân tích độ tương đồng ngữ nghĩa (Semantic Similarity) 14
2.3. Các mô hình học máy và học sâu trong phân loại tin tức 14
2.3.1. Thuật toán học máy truyền thống: Logistic Regression 14
2.3.2. Kiến trúc mạng học sâu Transformer 15
2.3.3. Mô hình ngôn ngữ lớn dựa trên BERT (PhoBERT) 15
2.4. Hệ thống đối soát và kiểm chứng thông tin thời gian thực 15
2.4.1. Cơ chế truy vấn dữ liệu trực tuyến (Real-time Web Querying) 16
2.4.2. Bộ lọc danh sách nguồn tin tin cậy (Trusted Source Whitelisting) 16
2.4.3. Đánh giá độ tin cậy dựa trên sự đồng thuận (Consensus Verification) 16

CHƯƠNG III: THIẾT KẾ HỆ THỐNG 17
3.1. Quy trình nghiệp vụ 17
3.2. Kiến trúc tổng thể của hệ thống 18
3.2.1. Sơ đồ khối chức năng 18
3.2.2. Hệ thống xử lý dữ liệu đa tầng 19
3.3. Xây dựng tập dữ liệu 19
3.3.1. Nguồn thu thập dữ liệu huấn luyện 19
3.3.2. Quy trình tiền xử lý dữ liệu 21
3.3.3. Module Phân tích đặc trưng văn phong 22
3.3.4. Module Phân loại ngữ nghĩa sâu (PhoBERT) 24
3.3.5. Module Kiểm chứng chéo và Đối soát nguồn tin 25
3.4. Thuật toán tổng hợp điểm và Cơ chế ra quyết định 27
3.4.1. Phương pháp tính toán trọng số đa tầng 27
3.4.2. Cơ chế xử lý ưu tiên và Ghi đè (Override Logic) 28
CHƯƠNG IV: THỰC NGHIỆM VÀ ĐÁNH GIÁ 29
4.1. Kết quả huấn luyện và Đánh giá mô hình AI 29
4.1.1. Đánh giá mô hình Logistic Regression 29
4.1.2. Đánh giá mô hình PhoBERT 31
4.3. Triển khai ứng dụng và Giao diện thực tế 33
CHƯƠNG V: THẢO LUẬN VÀ HẠN CHẾ 36
5.1. Phân tích sự tương quan giữa các mô hình thành phần 36
5.2. Hạn chế và các thách thức kỹ thuật 36
5.3. Bài học kinh nghiệm và Hướng phát triển 37
KẾT LUẬN 38
TÀI LIỆU THAM KHẢO 39

DANH MỤC CÁC HÌNH

Hình 1: Sơ đồ hoạt động hệ thống 17
Hình 2: Sơ đồ chức năng hệ thống 18
Hình 3: Báo cáo phân loại mô hình Logistic Regression 29
Hình 4: Biểu đồ ma trận nhầm lẫn mô hình Logistic Regression 30
Hình 5: Báo cáo phân loại mô hình PhoBERT 31
Hình 6: Ma trận nhầm lẫn mô hình PhoBERT 32
Hình 7: Giao diện trang chủ 33
Hình 8: Giao diện báo cáo kết quả đánh giá tin tức 34
Hình 9: Kết quả kiểm chứng chéo ngoại vi 34
Hình 10: Giao diện giải thích kết quả dự đoán 35

MỞ ĐẦU

Trong bối cảnh bùng nổ của cuộc Cách mạng Công nghiệp 4.0, không gian mạng đã trở thành môi trường truyền dẫn thông tin chủ đạo, đóng vai trò huyết mạch trong việc kết nối và định hướng dư luận xã hội. Tuy nhiên, sự phát triển mạnh mẽ này cũng kéo theo hệ lụy về nạn tin giả và thông tin sai lệch, gây ra những tác động tiêu cực đến an ninh chính trị, kinh tế và đời sống tinh thần của cộng đồng. Tại môi trường học thuật và giảng dạy, việc tiếp cận với các nguồn tin không chính thống không chỉ làm nhiễu loạn quá trình tiếp nhận tri thức mà còn đặt ra thách thức lớn trong việc bảo vệ tính khách quan và minh bạch của thông tin báo chí. Việc xây dựng một cơ chế kiểm chứng tin tức tự động, có khả năng phản ứng nhanh và chính xác, chính là chìa khóa để thanh lọc không gian số và bảo vệ người dùng trước các luồng thông tin độc hại.

Hệ thống tự động xác thực tin tức là một lĩnh vực nghiên cứu tiên phong, có sự giao thoa sâu sắc giữa công nghệ xử lý ngôn ngữ tự nhiên và trí tuệ nhân tạo. Khác với các phương pháp kiểm soát thông tin truyền thống vốn phụ thuộc nhiều vào nhân lực và thời gian, các hệ thống hiện đại cho phép bóc tách đa tầng dữ liệu văn bản để nhận diện các dấu hiệu giả mạo từ cấp độ ngữ nghĩa đến phong cách trình bày. Điều này đặc biệt có ý nghĩa thực tiễn khi kết hợp khả năng học sâu của máy tính với việc đối soát dữ liệu thực tế từ các nguồn tin cậy, giúp đưa ra những đánh giá mang tính định lượng và khách quan về độ tin cậy của một bản tin trước khi nó lan truyền rộng rãi.

Đề tài **"Nghiên cứu và xây dựng hệ thống kiểm chứng độ tin cậy tin tức tiếng Việt dựa trên mô hình học sâu và kiểm chứng nguồn tin thời gian thực"** được thực hiện nhằm khám phá các phương pháp tiếp cận tối ưu trong việc nhận diện tin giả. Nghiên cứu tập trung vào việc ứng dụng các kiến trúc học máy để phân tích ngữ nghĩa chuyên sâu, kết hợp cùng kỹ thuật trích xuất đặc trưng nhằm bóc tách văn phong giật gân và tích hợp cơ chế truy vấn dữ liệu trực tuyến để đối soát với hệ thống báo chí chính thống tại Việt Nam. Thông qua quá trình thiết kế và thử nghiệm thực nghiệm, đề án không chỉ cung cấp giải pháp kỹ thuật có độ chính xác cao mà còn đề xuất một quy trình minh bạch trong việc giải thích logic dự đoán của máy tính. Kết quả của nghiên cứu được kỳ vọng sẽ trở thành công cụ hỗ trợ đắc lực cho người dùng trong việc sàng lọc thông tin, góp phần xây dựng một môi trường văn hóa số an toàn và tin cậy.

CHƯƠNG I: GIỚI THIỆU

1.1. Lý do chọn đề tài

Trong kỷ nguyên số hiện nay, sự bùng nổ của mạng xã hội và các nền tảng truyền thông trực tuyến đã biến thông tin trở thành nguồn tài nguyên quan trọng, nhưng cũng đồng thời tạo điều kiện cho vấn nạn tin giả lan truyền với tốc độ chóng mặt. Tại Việt Nam, với hơn 70 triệu người dùng Internet, các thông tin sai lệch không chỉ gây nhiễu loạn thị trường, hoang mang dư luận mà còn đe dọa trực tiếp đến an ninh và trật tự xã hội. Việc kiểm chứng tin tức tiếng Việt hiện nay đối mặt với nhiều thách thức đặc thù do cấu trúc ngôn ngữ phức tạp, đa nghĩa và sự tinh vi trong cách ngụy trang thông tin. Các công cụ truyền thống dựa trên từ khóa hoặc đối soát thủ công thường bộc lộ hạn chế về độ trễ và chưa đủ khả năng hiểu sâu ngữ cảnh để phân biệt các dạng tin tức phức tạp.

Sự ra đời của các mô hình ngôn ngữ lớn (LLM) đã mở ra một hướng đi mới trong xử lý ngôn ngữ tự nhiên với khả năng phân tích logic và đối soát dữ liệu ở quy mô khổng lồ. Tuy nhiên, để khắc phục hiện tượng "ảo tưởng" của AI và đảm bảo tính xác thực tuyệt đối, việc kết hợp công nghệ này với cơ chế kiểm chứng nguồn tin thời gian thực là một giải pháp mang tính đột phá và cấp thiết. Nhận thức được tầm quan trọng của việc xây dựng một "màng lọc" thông tin thông minh nhằm bảo vệ người dùng và hỗ trợ công tác quản lý nội dung số, tôi quyết định tập trung nghiên cứu giải pháp tự động hóa quá trình xác thực độ tin cậy của tin tức. Nghiên cứu này không chỉ hướng tới việc ứng dụng những tiến bộ mới nhất của trí tuệ nhân tạo mà còn mong muốn đóng góp một công cụ thiết thực để xây dựng một môi trường mạng an toàn, minh bạch và tin cậy cho cộng đồng.

1.2. Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là nghiên cứu cơ sở lý thuyết và thực tiễn để xây dựng một hệ thống tự động có khả năng đánh giá độ tin cậy của tin tức tiếng Việt trên không gian mạng. Hệ thống này không chỉ dừng lại ở việc phân loại tin thật hay tin giả dựa trên xác suất thống kê, mà còn hướng tới việc cung cấp một cơ chế giải thích minh bạch thông qua việc đối soát dữ liệu đa nguồn và phân tích đặc trưng ngôn ngữ chuyên sâu. Thông qua đó, nghiên cứu góp phần hỗ trợ người dùng cuối và các nhà quản lý thông tin trong việc nhận diện và ngăn chặn sự lan truyền của các nội dung sai lệch trong môi trường số.

Để đạt được mục tiêu tổng quát nêu trên, đề tài xác lập các mục tiêu cụ thể bao gồm việc nghiên cứu và ứng dụng các kiến trúc học sâu tiên tiến nhất hiện nay trong xử lý ngôn ngữ tự nhiên để hiểu rõ ngữ nghĩa và ngữ cảnh của văn bản tiếng Việt. Bên cạnh đó, nghiên cứu tập trung vào việc xây dựng bộ tiêu chí đánh giá văn phong dựa trên các đặc trưng hình thái học và cú pháp học để nhận diện các thủ thuật gây sốc thường thấy trong tin đồn. Một mục tiêu trọng tâm khác là thiết kế và triển khai quy trình truy vấn dữ liệu thời gian thực từ các cơ quan báo chí chính thống, tạo ra một tầng kiểm chứng chéo khách quan nhằm đối chiếu các thực thể và sự kiện trong tin tức. Cuối cùng, nghiên cứu hướng tới việc hoàn thiện một mô hình thực nghiệm có giao diện tương tác trực quan, giúp chuyển hóa các chỉ số kỹ thuật phức tạp thành những giải thích logic dễ hiểu cho người sử dụng, đồng thời đảm bảo tính ổn định và hiệu suất trong môi trường vận hành thực tế.

1.3. Phạm vi nghiên cứu

Về mặt nội dung, đề tài tập trung nghiên cứu và xử lý dữ liệu dưới dạng văn bản tiếng Việt được chia sẻ trên các nền tảng số, bao gồm hệ thống báo chí điện tử, các trang tin tức tổng hợp và các bài viết có tính chất lan truyền trên mạng xã hội. Phạm vi phân tích không bao hàm các định dạng dữ liệu đa phương tiện khác như hình ảnh, âm thanh hay video giả mạo (Deepfake), mà chỉ đi sâu vào khai thác các đặc điểm ngôn ngữ, cấu trúc ngữ nghĩa và phong cách trình bày đặc trưng của tiếng Việt hiện đại. Việc giới hạn này giúp đảm bảo sự tập trung vào việc tối ưu hóa khả năng nhận diện các thủ thuật thao túng thông tin qua câu chữ và ngữ cảnh cụ thể.

Về mặt dữ liệu đối soát, nghiên cứu giới hạn việc kiểm chứng thông tin trong phạm vi các nguồn tin chính thống có tư cách pháp nhân, bao gồm hệ thống báo chí điện tử được cấp phép, các cổng thông tin điện tử của cơ quan Nhà nước và các tổ chức uy tín tại Việt Nam. Về mặt không gian và thời gian, đề tài ưu tiên các tin tức về các sự kiện, nhân vật và tổ chức diễn ra trong phạm vi lãnh thổ Việt Nam hoặc các vấn đề quốc tế có tác động trực tiếp đến dư luận trong nước. Các dữ liệu được sử dụng để thử nghiệm và đánh giá hệ thống là những thông tin có tính cập nhật, phản ánh thực trạng tin tức trong giai đoạn hiện nay, nhằm đảm bảo tính thực tiễn và khả năng ứng dụng cao của kết quả nghiên cứu.

1.4. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài được xác lập dựa trên hai nhóm chủ thể chính có mối quan hệ tương tác trực tiếp trong chu trình lan truyền và xác thực thông tin, cụ thể bao gồm:

- **Nhóm 1 – Nguồn tin và Nội dung tin tức:** Là các văn bản tiếng Việt được đăng tải và chia sẻ trên các nền tảng mạng xã hội như Facebook, TikTok, các diễn đàn trực tuyến và hệ thống báo chí điện tử. Nhóm đối tượng này bao hàm các loại hình tin thật, tin giả, tin sai lệch hoặc tin đồn thất thiệt liên quan đến các thực thể như nhân vật, tổ chức, địa danh và các sự kiện thời sự. Đây là đối tượng trực tiếp để hệ thống tiến hành bóc tách đặc trưng ngôn ngữ, phân tích cấu trúc ngữ nghĩa và thực hiện các thao tác kiểm chứng dữ liệu đa tầng.
- **Nhóm 2 – Người dùng và Đơn vị quản lý thông tin:** Là những cá nhân trực tiếp tiếp nhận tin tức trên không gian mạng và các tổ chức, đơn vị có chức năng giám sát, xử lý tin độc hại. Nhóm đối tượng này đóng vai trò là chủ thể thụ hưởng các kết quả từ hệ thống, sử dụng các chỉ số rủi ro và bảng giải thích logic để đưa ra quyết định tin tưởng hoặc ngăn chặn sự lan truyền của thông tin. Việc nghiên cứu nhu cầu và hành vi của nhóm này giúp hệ thống tối ưu hóa giao diện tương tác, đảm bảo các cảnh báo kỹ thuật được chuyển hóa thành những thông tin hỗ trợ ra quyết định một cách hiệu quả và chính xác nhất.

1.5. Ý nghĩa khoa học và thực tiễn

- **Ý nghĩa khoa học:** Đề tài góp phần hệ thống hóa và làm phong phú thêm cơ sở lý thuyết về việc ứng dụng trí tuệ nhân tạo trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt là đối với tiếng Việt – một ngôn ngữ có cấu trúc ngữ pháp và ngữ cảnh phức tạp. Nghiên cứu cung cấp một cách tiếp cận đa tầng trong việc xác thực thông tin, kết hợp giữa khả năng học sâu của các mô hình ngôn ngữ lớn để hiểu nội dung nội tại và cơ chế đối soát dữ liệu bên ngoài qua các thực thể có tên. Qua đó, đề tài đóng góp một mô hình thực nghiệm trong việc giải quyết bài toán tin giả, đồng thời mở ra hướng nghiên cứu về trí tuệ nhân tạo có khả năng giải thích (Explainable AI), giúp con người hiểu rõ logic phân tích của máy tính thay vì chỉ tiếp nhận các kết quả dự báo thuần túy.
- **Ý nghĩa thực tiễn:** Về mặt ứng dụng, đề tài xây dựng thành công một công cụ hỗ trợ người dùng nhận diện và cảnh báo tin tức độc hại một cách nhanh chóng và trực quan trên không gian mạng. Hệ thống không chỉ giúp cá nhân tự bảo vệ trước các luồng thông tin sai lệch mà còn hỗ trợ các cơ quan, tổ chức trong việc giám sát và quản lý uy tín truyền thông, ngăn chặn những hệ lụy tiêu cực về kinh tế và xã hội do tin giả gây ra. Đặc biệt, thông qua bảng giải thích chi tiết và việc phân loại nguồn tin chính thống, hệ thống góp phần nâng cao kỹ năng thẩm định thông tin và ý thức sử dụng mạng xã hội an toàn cho cộng đồng. Đây là giải pháp thiết thực để thanh lọc môi trường số, thúc đẩy việc lan truyền các giá trị thông tin xác thực và xây dựng một không gian mạng văn minh, tin cậy.

1.6. Tổng quan các nghiên cứu trước đây

1.6.1. Các nghiên cứu về nhận diện tin giả dựa trên học máy và học sâu

Sự bùng nổ của thông tin sai lệch trên các nền tảng mạng xã hội đã gây ra những mối đe dọa nghiêm trọng đến trật tự xã hội, niềm tin công chúng và tính trung thực của thông tin (Lv et al., 2025; Salve, 2025). Trước bối cảnh đó, các nghiên cứu quốc tế đã chuyển dịch mạnh mẽ từ phương pháp kiểm chứng thủ công sang ứng dụng trí tuệ nhân tạo (AI) và học sâu (Deep Learning) nhằm tự động hóa quy trình phát hiện với độ chính xác và tốc độ xử lý vượt trội (Raza et al., 2025; Salve, 2025).

Trong giai đoạn đầu của các kỹ thuật học sâu, mạng nơ-ron tái hồi, đặc biệt là Long Short-Term Memory (LSTM), được ưa chuộng nhờ khả năng ghi nhớ các phụ thuộc ngữ nghĩa trong các chuỗi văn bản dài, giúp mang lại kết quả chính xác và đáng tin cậy hơn so với các phương pháp học máy truyền thống (Salve, 2025). Bên cạnh việc phân loại văn bản đơn thuần, hướng tiếp cận phát hiện lập trường (stance detection) cũng được chú trọng để xác định mối quan hệ giữa tiêu đề và nội dung bài báo (Thota et al., 2018). Bằng cách kết hợp đặc trưng TF-IDF và mạng nơ-ron dày đặc (DNN), các mô hình này có thể đạt độ chính xác lên tới 94,21% trong việc xác định liệu nội dung bài báo có đồng ý, phản đối hay thảo luận về tiêu đề hay không (Thota et al., 2018).

Sự ra đời của kiến trúc Transformer và các mô hình như BERT đã nâng cao đáng kể khả năng hiểu ngữ cảnh sâu sắc của văn bản (Raza et al., 2025). Các nghiên cứu thực nghiệm cho thấy các mô hình chỉ mã hóa (encoder-only) như BERT hay RoBERTa thường có hiệu suất phân loại vượt trội so với các mô hình ngôn ngữ lớn (LLMs) trong các tác vụ nhận diện tin giả tiêu chuẩn (Raza et al., 2025). Tuy nhiên, LLMs lại thể hiện độ bền vững (robustness) cao hơn trước các biến đổi văn bản hoặc các cuộc tấn công đối kháng, đồng thời có thể đóng vai trò là công cụ dán nhãn dữ liệu tự động hiệu quả khi có sự giám sát của con người (Raza et al., 2025).

Xu hướng hiện đại trong phát hiện tin giả quốc tế đang chuyển dịch mạnh mẽ sang hướng đa phương thức (multi-modal) (Lv et al., 2025). Các nghiên cứu khảo sát chỉ ra rằng việc kết hợp đồng thời văn bản, hình ảnh, video và âm thanh giúp mô hình nắm bắt được sự không nhất quán giữa các loại dữ liệu khác nhau, từ đó tăng cường độ chính xác trong việc phát hiện các nội dung bị chỉnh sửa tinh vi như Deepfake (Lv et al., 2025). Ngoài ra, việc tích hợp các đặc trưng từ mạng lưới xã hội và cơ chế chú ý (attention mechanism) cũng giúp mô hình hiểu rõ hơn về hành vi lan truyền và tương tác của người dùng đối với các nguồn tin không đáng tin cậy (Lv et al., 2025).

1.6.2. Các nghiên cứu đặc thù cho ngôn ngữ Tiếng Việt

Nghiên cứu nhận diện tin giả trong ngữ cảnh tiếng Việt đối mặt với những thách thức riêng biệt do cấu trúc cú pháp phức tạp, tính đa nghĩa của từ vựng và sự khan hiếm của các bộ dữ liệu chất lượng cao được dán nhãn thủ công (Vinh & Do,

2023). Sự khác biệt về cú pháp giữa tiếng Việt và tiếng Anh thường dẫn đến những khó khăn trong việc diễn giải chính xác ngữ nghĩa của câu, đòi hỏi các bước tiền xử lý đặc thù như tách từ (word segmentation) thông qua các công cụ như VnCoreNLP trước khi đưa vào mô hình học sâu (Vinh & Do, 2023; Pham Dang et al., 2023). Để giải quyết vấn đề thiếu hụt dữ liệu, các nhà nghiên cứu tại Việt Nam đã tập trung xây dựng các tập dữ liệu bản địa như VNFD hoặc các bộ dữ liệu phục vụ thử thách ReINTEL tại hội thảo VLSP, thu thập từ các nguồn báo chí chính thống kết hợp với thông tin từ mạng xã hội (Minh et al., 2020; Vinh & Do, 2023).

Về mặt kiến trúc mô hình, xu hướng chủ đạo là phát triển các mô hình lai (hybrid models) nhằm trích xuất đa dạng đặc trưng của văn bản tiếng Việt. Ninh et al. (2025) đã đề xuất một kiến trúc kết hợp giữa Transformer, Bi-LSTM và CNN để khai thác đồng thời đặc trưng ngữ nghĩa, sự phụ thuộc tuần tự và cấu trúc cục bộ, đạt độ chính xác ấn tượng lên tới 95,3%. Các thử nghiệm so sánh cũng chỉ ra rằng mô hình CNN-BiLSTM mang lại hiệu quả cao hơn các kiến trúc đơn lẻ trong việc nhận diện các biến thể tin giả tiếng Việt (Vinh & Do, 2023). Bên cạnh đó, việc ứng dụng các mô hình ngôn ngữ đã được huấn luyện trước (pre-trained) dành riêng cho tiếng Việt như PhoBERT và vELECTRA đã tạo ra những bước tiến vượt bậc về hiệu suất (Minh et al., 2020; Pham Dang et al., 2023).

Một hướng tiếp cận đổi mới trong các nghiên cứu gần đây là việc tích hợp siêu dữ liệu (metadata) từ mạng xã hội. Minh et al. (2020) đã sử dụng phương pháp Ensemble kết hợp PhoBERT với các thông tin tương tác như lượt like, share và comment để giành giải nhất trong cuộc thi ReINTEL 2020. Đặc biệt, nghiên cứu của Pham Dang et al. (2023) đã đề xuất phương pháp chuyển đổi các con số siêu dữ liệu thành dạng "văn bản diễn giải" (verbal words) để các mô hình BERT có thể hiểu trực tiếp ngữ cảnh tương tác, giúp đạt kết quả SOTA (tốt nhất hiện nay) với điểm AUC là 0,9575. Ngoài phân tích nội dung, các nghiên cứu hiện đại còn mở rộng sang hướng kiểm chứng thông tin thông qua Đồ thị tri thức (Knowledge Graph) kết hợp với kiến trúc KG-BERT, giúp mô hình có khả năng suy luận trên các bộ ba tri thức (triples) để xác thực tính đúng đắn của các tuyên bố phức tạp trong tiếng Việt (Duong et al., 2023).

1.6.3. Khoảng trống nghiên cứu

Mặc dù đã có nhiều tiến bộ đáng kể trong việc ứng dụng học sâu và các mô hình ngôn ngữ lớn để nhận diện tin giả, các nghiên cứu hiện tại vẫn tồn tại những khoảng trống quan trọng cần được tiếp tục khám phá.

Thứ nhất là sự hạn chế về dữ liệu chất lượng cao và đặc thù ngôn ngữ. Phần lớn các bộ dữ liệu quy mô lớn hiện nay tập trung vào tiếng Anh, trong khi các ngôn ngữ có nguồn tài nguyên thấp như tiếng Việt vẫn đối mặt với tình trạng khan hiếm dữ liệu

được dán nhãn thủ công bởi chuyên gia (Ninh et al., 2025; Vinh & Do, 2023). Các nghiên cứu tại Việt Nam thường phải đối mặt với khó khăn trong việc xây dựng các bộ dữ liệu đủ lớn và cập nhật để bao quát các kịch bản tin giả ngày càng tinh vi trên mạng xã hội (Minh et al., 2020; Vinh & Do, 2023). Bên cạnh đó, việc dán nhãn dữ liệu dựa trên nguồn tin (distant supervision) thường dẫn đến sai số và không bắt kịp được các sắc thái ngữ cảnh tinh tế của từng bài báo (Raza et al., 2025).

Thứ hai là sự đánh đổi giữa hiệu suất phân loại và độ bền vững của mô hình. Các nghiên cứu so sánh cho thấy các mô hình họ BERT mặc dù đạt độ chính xác cao trong môi trường ổn định nhưng lại dễ bị tổn thương trước các biến đổi văn bản (perturbations) hoặc các cuộc tấn công đối kháng (Raza et al., 2025). Ngược lại, các mô hình ngôn ngữ lớn (LLMs) dù thể hiện độ bền vững cao hơn nhưng lại yêu cầu tài nguyên tính toán cực lớn, gây khó khăn cho việc triển khai trong thực tế với các hệ thống cần phản hồi thời gian thực (Raza et al., 2025; Lv et al., 2025). Khoảng trống nghiên cứu nằm ở việc tìm ra một cơ chế lai tối ưu (hybrid approach) để tận dụng đồng thời tính chính xác của BERT và tính bền vững của LLM mà vẫn đảm bảo hiệu quả về chi phí tính toán (Raza et al., 2025).

Thứ ba là thách thức trong việc thu hẹp khoảng cách ngữ nghĩa đa phương thức. Mặc dù xu hướng phát hiện đa phương thức (văn bản, hình ảnh, video) đang phát triển, việc thiết lập các cơ chế hợp nhất đặc trưng (feature fusion) hiệu quả giữa các loại dữ liệu không đồng nhất vẫn là một bài toán khó (Lv et al., 2025). Hiện tại, tình trạng không nhất quán về mặt ngữ nghĩa giữa nội dung văn bản và bằng chứng hình ảnh (semantic gaps) thường dẫn đến việc mô hình đưa ra các dự đoán sai lệch (Lv et al., 2025). Hơn nữa, các công nghệ như Deepfake trong video và âm thanh vẫn đang tạo ra những rào cản kỹ thuật mà các mô hình nhận diện hiện nay chưa thể xử lý triệt để (Lv et al., 2025).

Cuối cùng là tính giải thích được (explainability) và khả năng phát hiện sớm. Hầu hết các hệ thống hiện nay hoạt động như những "hộp đen" (black boxes), đưa ra kết quả phân loại mà không cung cấp lý do cụ thể tại sao một tin tức bị coi là giả (Lv et al., 2025; Raza et al., 2025). Điều này làm giảm niềm tin của người dùng và gây khó khăn cho việc ứng dụng trong các cơ quan kiểm chứng tin tức chuyên nghiệp. Ngoài ra, việc phát hiện tin giả ở giai đoạn sớm khi thông tin vừa mới bắt đầu lan truyền và chưa có nhiều siêu dữ liệu tương tác vẫn là một thách thức lớn chưa có lời giải thỏa đáng trong các nghiên cứu hiện tại (Lv et al., 2025; Vinh & Do, 2023).

CHƯƠNG II: CƠ SỞ LÝ THUYẾT

2.1. Tin giả và thông tin sai lệch

2.1.1. Khái niệm và Phân loại

Trong kỷ nguyên thông tin số, thuật ngữ "tin giả" (Fake news) thường được dùng để chỉ các nội dung không chính xác, nhưng về mặt khoa học, thực thể này được chia thành ba cấp độ dựa trên ý đồ của người tạo và tính xác thực của nội dung:

- Thông tin sai lệch vô ý (Misinformation): Là những thông tin không đúng sự thật nhưng được chia sẻ mà không có mục đích xấu (ví dụ: người dùng chia sẻ lại một tin cũ từ nhiều năm trước vì tưởng là tin mới).
- Thông tin sai lệch có ý đồ (Disinformation): Là thông tin được tạo ra và phát tán một cách có tính toán nhằm lừa dối dư luận, gây hoang mang hoặc phục vụ mục đích chính trị, kinh tế bất chính. Đây là đối tượng trọng tâm mà các hệ thống AI cần ngăn chặn.
- Thông tin độc hại (Malinformation): Là những thông tin có thật nhưng được dùng sai ngữ cảnh hoặc bị cắt ghép để bôi nhọ, gây hại cho một đối tượng cụ thể.

2.1.2. Các hình thức biểu hiện phổ biến của tin giả

Tin giả hiện nay không chỉ tồn tại dưới dạng bịa đặt hoàn toàn mà còn được ngụy trang dưới nhiều hình thức tinh vi để đánh lừa bộ lọc của con người:

- Nội dung sai ngữ cảnh: Sử dụng hình ảnh hoặc sự kiện có thật nhưng gán cho một thời điểm hoặc địa điểm hoàn toàn khác.
- Tiêu đề giật gân (Clickbait): Tiêu đề bài viết được phóng đại hoặc gây sốc, không phản ánh đúng nội dung bên trong nhằm mục đích lôi kéo lượt tương tác.
- Mạo danh nguồn tin uy tín: Thiết kế giao diện hoặc sử dụng tên miền gần giống với các tờ báo chính thống (ví dụ: thay đổi một ký tự trong tên miền của báo VnExpress hay Tuổi Trẻ) để tạo lòng tin giả tạo.

2.1.3. Hệ lụy của tin giả đối với xã hội

Sự lan truyền của tin giả gây ra những hậu quả nghiêm trọng và đa diện. Về mặt tâm lý, nó gieo rắc sự hoài nghi và gây chia rẽ trong cộng đồng. Về mặt kinh tế,

tin giả về thị trường tài chính hoặc doanh nghiệp có thể gây thiệt hại hàng tỷ đồng chỉ trong thời gian ngắn. Đặc biệt trong môi trường học thuật, việc tiếp cận thông tin sai lệch làm giảm khả năng tư duy phản biện và gây nhiễu loạn quá trình tiếp nhận tri thức của người học. Do đó, việc nghiên cứu các cơ chế tự động để phát hiện và cảnh báo tin giả là một yêu cầu tất yếu để bảo vệ sự trong sạch của không gian mạng.

2.2. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)

2.2.1. Khái niệm cơ bản

Xử lý ngôn ngữ tự nhiên (NLP) là một nhánh của Trí tuệ nhân tạo, tập trung vào việc nghiên cứu sự tương tác giữa máy tính và ngôn ngữ tự nhiên của con người. Mục tiêu cốt lõi của NLP trong đề tài này là giúp hệ thống có khả năng "hiểu" ngữ nghĩa, ngữ cảnh và sắc thái của các bản tin tiếng Việt, từ đó đưa ra các phán quyết về độ tin cậy dựa trên dữ liệu định lượng thay vì cảm tính.

2.2.2. Các kỹ thuật tiền xử lý văn bản tiếng Việt

Để mô hình có thể phân tích chính xác, dữ liệu thô từ mạng xã hội hoặc báo chí cần trải qua quy trình tiền xử lý nghiêm ngặt nhằm loại bỏ nhiễu và chuẩn hóa cấu trúc:

- Chuẩn hóa văn bản (Text Normalization): Chuyển đổi toàn bộ văn bản về dạng chữ thường, loại bỏ các ký tự đặc biệt, các biểu tượng (emoji) không cần thiết và chuẩn hóa cách gõ dấu tiếng Việt (ví dụ: "hòa" thay vì "hoà").
- Tách từ (Tokenization): Đây là bước quan trọng nhất đối với tiếng Việt – một ngôn ngữ đơn lập. Khác với tiếng Anh (phân tách từ bằng khoảng trắng), tiếng Việt có nhiều từ ghép (ví dụ: "sinh viên", "học tập"). Hệ thống sử dụng thư viện chuyên dụng để nhận diện các cụm từ có nghĩa, giúp máy tính không hiểu nhầm các từ đơn lẻ.
- Loại bỏ từ dừng (Stopwords Removal): Loại bỏ các từ xuất hiện thường xuyên nhưng mang ít ý nghĩa về mặt nội dung như "và", "của", "là", "những" để tập trung vào các từ mang tính từ khóa (keywords).

2.2.3. Biểu diễn văn bản dưới dạng Vector (Word Embedding)

Máy tính không thể hiểu trực tiếp các ký tự chữ viết, do đó văn bản cần được chuyển đổi thành các dãy số (Vector). Đề tài ứng dụng hai phương pháp chính:

- TF-IDF (Term Frequency-Inverse Document Frequency)**:** Kỹ thuật này giúp đánh giá tầm quan trọng của một từ trong bản tin. Những từ xuất hiện nhiều

trong một bài nhưng ít xuất hiện ở các bài khác sẽ được gán trọng số cao, giúp hệ thống nhận diện được chủ đề cốt lõi của tin tức.

- Word Embeddings (Nhúng từ): Sử dụng các không gian vector đa chiều để biểu diễn từ ngữ. Các từ có nghĩa tương đồng (ví dụ: "giả mạo" và "sai trái") sẽ nằm gần nhau trong không gian này, giúp mô hình hiểu được mối quan hệ ngữ nghĩa sâu sắc thay vì chỉ so khớp ký tự thuần túy.

2.2.4. Phân tích độ tương đồng ngữ nghĩa (Semantic Similarity)

Trong cơ chế kiểm chứng chéo của hệ thống, kỹ thuật NLP được dùng để so sánh mức độ trùng khớp giữa nội dung tin đồn và các bài báo chính thống tìm thấy trên Google. Đề tài sử dụng Độ tương đồng Cosine (Cosine Similarity) để đo lường góc giữa hai vector đại diện cho hai đoạn văn bản. Nếu giá trị này tiến gần về 1, hệ thống xác nhận nội dung đang kiểm tra có sự đồng nhất cao với các nguồn tin uy tín, từ đó làm cơ sở để hạ thấp chỉ số rủi ro.

2.3. Các mô hình học máy và học sâu trong phân loại tin tức

2.3.1. Thuật toán học máy truyền thống: Logistic Regression

Logistic Regression là một thuật toán học máy có giám sát (supervised learning) được sử dụng để dự đoán xác suất của một biến mục tiêu có tính chất nhị phân (Binary Classification). Khác với hồi quy tuyến tính dự đoán giá trị liên tục, Logistic Regression sử dụng hàm Logistic (hàm Sigmoid) để ánh xạ các giá trị đầu vào thành một giá trị xác suất nằm trong khoảng từ 0 đến 1.

Trong bài toán phân loại tin tức, các đặc trưng về văn phong như tần suất dùng từ cảm thán, tỷ lệ viết hoa và độ dài câu đóng vai trò quan trọng trong việc nhận diện tin giả. Đề tài lựa chọn Logistic Regression để xử lý tầng phân tích rủi ro văn phong vì những ưu điểm sau:

- Tính tường minh: Khác với các mô hình "hộp đen", thuật toán này cho phép quan sát rõ trọng số của từng đặc trưng (ví dụ: một từ khóa giật gân đóng góp bao nhiêu phần trăm vào khả năng là tin giả).
- Hiệu suất xử lý: Tốc độ tính toán cực nhanh, phù hợp để xử lý các thuộc tính dạng số từ bộ trích xuất đặc trưng văn phong mà không gây trễ cho hệ thống.
- Độ ổn định: Mang lại độ chính xác cao đối với các tập dữ liệu có cấu trúc rõ ràng và ít bị hiện tượng quá khớp (overfitting).

2.3.2. Kiến trúc mạng học sâu Transformer

Transformer là một kiến trúc mạng nơ-ron được giới thiệu bởi Google vào năm 2017, dựa hoàn toàn trên cơ chế "chú ý" (Attention Mechanism) để xử lý dữ liệu dạng chuỗi. Điểm khác biệt cốt lõi của Transformer so với các mạng truyền thống là nó không xử lý dữ liệu theo thứ tự tuần tự mà cho phép máy tính "quan sát" toàn bộ các từ trong văn bản cùng một lúc.

Mô tả cơ chế hoạt động:

- Cơ chế Self-Attention (Tự chú ý): Cho phép mô hình đánh giá mức độ quan trọng của tất cả các từ trong một câu tại cùng một thời điểm. Điều này giúp mô hình hiểu được mối liên hệ ngữ nghĩa giữa các từ đứng xa nhau, từ đó nắm bắt được ngữ cảnh phức tạp của các bản tin dài mà các kiến trúc cũ thường bỏ sót.
- Xử lý song song: Transformer cho phép tính toán dữ liệu đồng thời, giúp rút ngắn thời gian huấn luyện và tăng cường khả năng học hỏi từ các tập dữ liệu văn bản khổng lồ.

2.3.3. Mô hình ngôn ngữ lớn dựa trên BERT (PhoBERT)

BERT (Bidirectional Encoder Representations from Transformers) là một mô hình ngôn ngữ tiền huấn luyện (Pre-trained) sử dụng kỹ thuật học theo cả hai chiều (trái sang phải và phải sang trái) để hiểu ngữ cảnh của một từ dựa trên tất cả các từ xung quanh nó. PhoBERT là phiên bản tối ưu hóa của kiến trúc RoBERTa (một cải tiến của BERT), được huấn luyện chuyên biệt trên tập dữ liệu tiếng Việt quy mô lớn.

Đặc điểm và ứng dụng:

- Tối ưu cho tiếng Việt: PhoBERT được huấn luyện trên tập dữ liệu 20GB văn bản tiếng Việt thuần túy. Điều này giúp mô hình vượt trội trong việc hiểu các sắc thái ngữ nghĩa, từ lóng và cấu trúc câu đặc thù của người Việt, điều mà các mô hình đa ngôn ngữ quốc tế thường gặp hạn chế.
- Vai trò trong hệ thống: PhoBERT đóng vai trò là "bộ não" chính, thực hiện nhiệm vụ phân loại ngữ nghĩa sâu (Semantic Risk). Mô hình chuyển hóa nội dung tin tức thành các không gian vector đa chiều phức tạp để nhận diện các mẫu hình thông tin rủi ro thường thấy trong các chiến dịch tin giả tinh vi.

2.4. Hệ thống đối soát và kiểm chứng thông tin thời gian thực

Bên cạnh việc phân tích đặc trưng nội tại của văn bản bằng các mô hình học máy, hệ thống còn xây dựng một lớp xác thực ngoại vi dựa trên dữ liệu thực tế từ

mạng Internet. Cơ chế này đóng vai trò quyết định trong việc khẳng định một bản tin là xác thực hay sai lệch dựa trên sự hiện diện của nó trên các nguồn tin uy tín.

2.4.1. Cơ chế truy vấn dữ liệu trực tuyến (Real-time Web Querying)

Do các mô hình ngôn ngữ như PhoBERT có giới hạn về thời điểm cập nhật dữ liệu huấn luyện, hệ thống cần một cơ chế để tiếp cận với những sự kiện đang diễn ra trong thời gian thực.

- Quy trình: Khi một bản tin được đưa vào, hệ thống tự động bóc tách các từ khóa trọng tâm và sử dụng các công cụ tìm kiếm (Search Engine API) để quét toàn bộ không gian mạng.
- Mục tiêu: Tìm kiếm sự tương quan giữa nội dung đầu vào và các luồng thông tin đang lưu hành, từ đó xác định xem thông tin này có đang được các cơ quan chức năng hoặc báo chí đề cập hay không.

2.4.2. Bộ lọc danh sách nguồn tin tin cậy (Trusted Source Whitelisting)

Để đảm bảo dữ liệu đối soát là chính xác tuyệt đối, hệ thống áp dụng kỹ thuật Whitelisting (Danh sách trắng). Đây là một cơ sở dữ liệu chứa các tên miền (Domain) của các tổ chức có tư cách pháp nhân và độ uy tín cao, bao gồm:

- Hệ thống báo chí chính thống: Các tờ báo điện tử lớn như *VnExpress, Tuổi Trẻ, Nhân Dân, VietnamPlus...*
- Cổng thông tin Chính phủ: Các trang có đuôi tên miền .gov.vn của các Bộ, ngành và địa phương.
- Tổ chức quốc tế: Các nguồn tin từ các đơn vị uy tín như WHO, Liên Hợp Quốc hoặc các hãng thông tấn lớn.

2.4.3. Đánh giá độ tin cậy dựa trên sự đồng thuận (Consensus Verification)

Sau khi thu thập kết quả từ các nguồn tin tin cậy, hệ thống thực hiện phép tính độ tương đồng ngữ nghĩa (Cosine Similarity).

- Nguyên lý đồng thuận: Nếu bản tin đầu vào có sự trùng khớp cao về mặt nội dung với thông tin trên các trang thuộc danh sách trắng, hệ thống sẽ xác nhận đây là tin chính thống.
- Cảnh báo sai lệch: Ngược lại, nếu một bản tin có nội dung mang tính chất "sự kiện" nhưng hoàn toàn không xuất hiện trên bất kỳ phương tiện thông tin đại chúng nào, hoặc chỉ xuất hiện trên các trang web lạ, mạng xã hội cá nhân, hệ thống sẽ tự động nâng mức độ rủi ro và đưa ra cảnh báo cho người dùng.

CHƯƠNG III: THIẾT KẾ HỆ THỐNG

3.1. Quy trình nghiệp vụ

Quy trình nghiệp vụ của hệ thống được xây dựng dựa trên việc mô phỏng và tối ưu hóa các bước xác thực thông tin của một người dùng có kinh nghiệm trong môi trường số. Trong thực tế, khi tiếp cận một bản tin nghi vấn, quy trình nghiệp vụ thông thường bao gồm việc đánh giá cảm tính về văn phong, phân tích nội dung và chủ động tìm kiếm các nguồn tin đối chứng. Hệ thống đã tự động hóa quy trình này thành một luồng xử lý khép kín và khách quan.

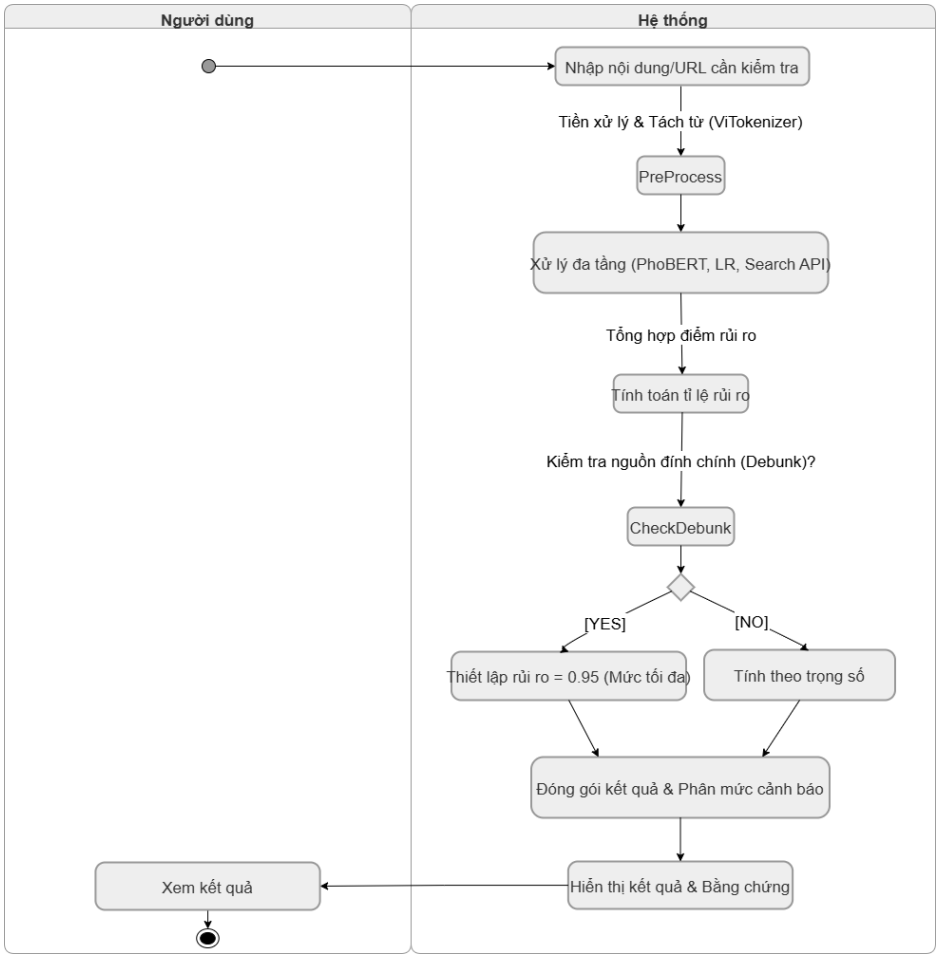

Hình 1: Sơ đồ hoạt động hệ thống

Cụ thể, quy trình nghiệp vụ thực tế của hệ thống được triển khai qua các bước sau:

- Tiếp nhận và Sơ duyệt: Hệ thống tiếp nhận dữ liệu đầu vào từ người dùng dưới dạng văn bản thuần túy hoặc đường dẫn (URL) của bài báo. Ngay lập

tức, quy trình tiền xử lý nghiệp vụ sẽ thực hiện chuẩn hóa văn bản và tách từ tiếng Việt để đảm bảo dữ liệu sẵn sàng cho các tầng phân tích chuyên sâu.

- Phân tích đa chiều: Thay vì chỉ dựa vào một phương pháp duy nhất, nghiệp vụ của hệ thống thực hiện kiểm chứng đồng thời trên ba phương diện: ngữ nghĩa sâu, đặc trưng văn phong và bằng chứng thực tế. Việc chạy song song các module này giúp hệ thống có cái nhìn toàn diện, tránh được sự phiến diện khi bản tin có nội dung phức tạp.
- Đối soát và Xác thực nguồn tin: Hệ thống thực hiện nghiệp vụ tìm kiếm thông tin tương ứng trên không gian mạng, đặc biệt ưu tiên đối soát với danh sách các cơ quan thông tấn và báo chí chính thống. Đây là bước quan trọng nhất để đảm bảo tính thực chứng cho kết luận cuối cùng.
- Tổng hợp và Ra quyết định: Quy trình này kết thúc bằng việc trình bày một báo cáo minh bạch cho người dùng, bao gồm điểm số rủi ro và các bằng chứng đối soát cụ thể.

3.2. Kiến trúc tổng thể của hệ thống

3.2.1. Sơ đồ khối chức năng

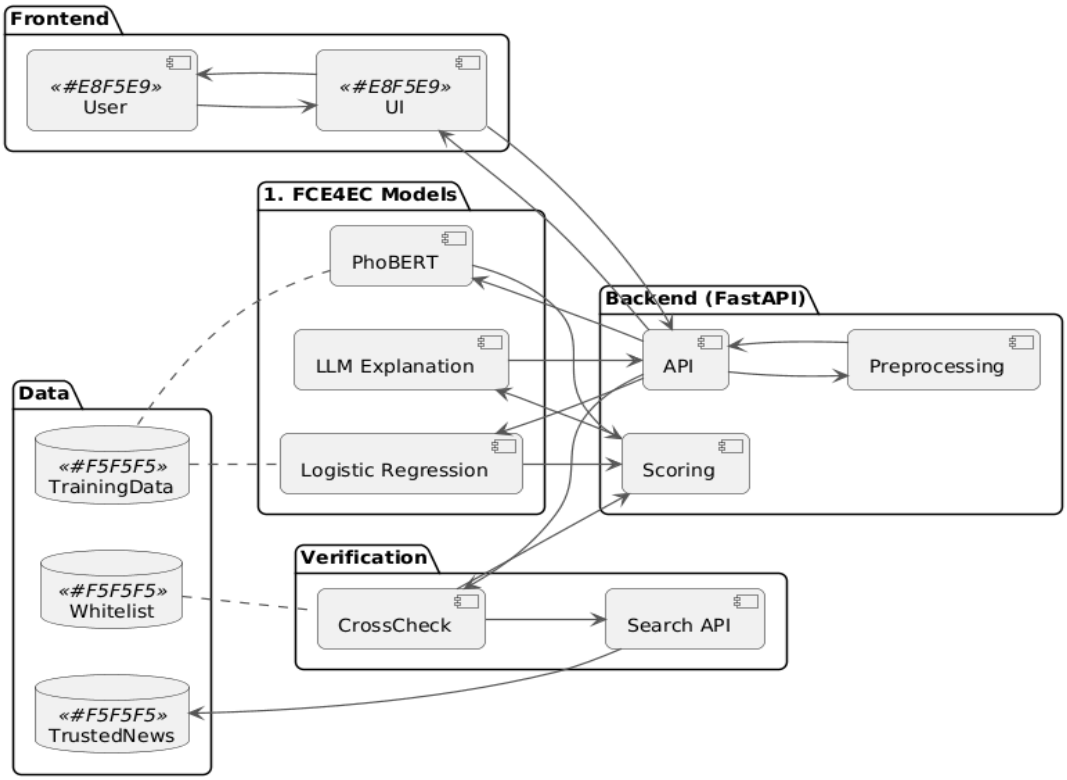

Hình 2: Sơ đồ chức năng hệ thống

Hệ thống được thiết kế theo kiến trúc đa tầng nhằm tối ưu hóa khả năng phân tích ngữ nghĩa và đối soát thực tế. Kiến trúc tổng thể bao gồm bốn lớp chính tương tác chặt chẽ với nhau: lớp giao diện (Frontend), lớp xử lý trung tâm (Backend), lớp phân tích thông minh (AI Models) và lớp xác thực ngoại vi (Verification Layer).

Tại lớp giao diện, người dùng cung cấp nội dung tin tức cần kiểm tra, dữ liệu này sau đó được chuyển đến lớp xử lý trung tâm để thực hiện các bước tiền xử lý ngôn ngữ chuyên sâu. Điểm đặc biệt của kiến trúc này là sự kết hợp song song giữa việc phân tích đặc trưng nội tại của văn bản thông qua các mô hình học máy như PhoBERT và Logistic Regression cùng việc truy vấn dữ liệu thực chứng thời gian thực từ Internet. Kết quả từ các tầng phân tích sẽ được tập hợp tại module tổng hợp dựa trên thuật toán trọng số và cơ chế ghi đè logic, cho phép hệ thống đưa ra chỉ số rủi ro cuối cùng kèm theo các bằng chứng đối soát cụ thể từ nguồn tin chính thống, đảm bảo tính khách quan và độ tin cậy cao cho quy trình xác thực.

3.2.2. Hệ thống xử lý dữ liệu đa tầng

Quy trình xử lý dữ liệu của hệ thống được thực hiện theo một luồng khép kín nhằm đảm bảo tính chính xác và tốc độ phản hồi. Luồng dữ liệu bắt đầu từ giai đoạn Tiếp nhận và Tiền xử lý, nơi văn bản thô được chuẩn hóa và tách từ để sẵn sàng cho các phân tích tiếp theo.

Giai đoạn thứ hai là Phân tích đa chiều, dữ liệu được đẩy đồng thời vào hai nhánh. Nhánh thứ nhất đánh giá rủi ro dựa trên văn phong và ngữ nghĩa thông qua các mô hình đã được huấn luyện. Nhánh thứ hai thực hiện trích xuất các từ khóa sự kiện để tiến hành truy vấn trên các công cụ tìm kiếm. Dữ liệu trả về từ các nguồn tin tin cậy (Whitelisted Domains) sẽ được so sánh độ tương đồng với nội dung gốc.

Giai đoạn cuối cùng là Tổng hợp và Suy luận. Tại đây, hệ thống sử dụng một thuật toán tính điểm trọng số để kết hợp các chỉ số rủi ro từ tất cả các tầng xử lý. Quy trình này đảm bảo rằng mỗi kết quả trả về cho người dùng đều đi kèm với các bằng chứng thực tế và lập luận khoa học, loại bỏ tính chất "hộp đen" thường gặp trong các hệ thống trí tuệ nhân tạo truyền thống.

3.3. Xây dựng tập dữ liệu

3.3.1. Nguồn thu thập dữ liệu huấn luyện

Để xây dựng một hệ thống có khả năng nhận diện tin giả với độ chính xác cao, việc lựa chọn nguồn dữ liệu đầu vào đóng vai trò quyết định. Tập dữ liệu huấn luyện cho đề tài được tổng hợp từ ba nguồn chính, đảm bảo tính cân bằng giữa các mẫu tin xác thực (Label: 0) và các mẫu tin giả mạo hoặc tin đồn chưa kiểm chứng (Label: 1).

a. *Nguồn tin tức chính thống (Dữ liệu tin thật – Authentic Data):*

Nhóm dữ liệu này được khai thác từ các cơ quan báo chí uy tín và các cổng thông tin điện tử của Chính phủ Việt Nam. Đây là nguồn dữ liệu chuẩn để mô hình học tập văn phong báo chí chuyên nghiệp, khách quan. Các nguồn cụ thể bao gồm:

- Báo điện tử lớn: VnExpress, Tuổi Trẻ, Thanh Niên, VietnamPlus.
- Cổng thông tin cơ quan nhà nước: Cổng thông tin điện tử Chính phủ (chinhphu.vn), Bộ Công an, Bộ Y tế.
- Thông tấn xã: Thông tấn xã Việt Nam (VNA).

b. Nguồn tin mạng xã hội và diễn đàn (Dữ liệu tin giả/tin đồn – Fake/Rumor Data):

Để mô hình nhận diện được các đặc trưng của tin giả, hệ thống thu thập dữ liệu từ các nền tảng có tốc độ lan truyền thông tin nhanh nhưng thiếu sự kiểm duyệt chặt chẽ. Dữ liệu tại đây thường có đặc điểm là văn phong gây sốc, sử dụng nhiều từ ngữ cảm thán hoặc cấu trúc câu không chính quy. Các nguồn thu thập bao gồm:

- Mạng xã hội: Các hội nhóm công khai trên Facebook, Zalo thường xuyên chia sẻ các thông tin về y tế, từ thiện và biến động thị trường.
- Trang tin tổng hợp không chính thống: Các trang tin "lá cải", blog cá nhân tự phát không có giấy phép hoạt động báo chí.
- Dữ liệu đính chính: Thu thập từ các chuyên mục "Kiểm chứng tin" hoặc "Tin giả - Tin thật" của Trung tâm Tin giả Việt Nam (VAFC).

c. Các tập dữ liệu mở (Public Datasets):

Nhằm tăng cường kích thước tập mẫu và đảm bảo tính khách quan cho quá trình huấn luyện, đề tài cũng kế thừa và chọn lọc dữ liệu từ các bộ Dataset tin tức tiếng Việt nổi tiếng trong cộng đồng nghiên cứu chia sẻ tập dữ liệu như:

- Fake News Vietnamese Dataset: Đây là tập dữ liệu nền tảng cung cấp các mẫu tin tức đa dạng về nhiều chủ đề. Tập dữ liệu này giúp mô hình làm quen với các cấu trúc tin giả phổ biến tại Việt Nam, từ đó nhận diện được các đặc trưng ngôn ngữ thường xuất hiện trong các bản tin thiếu xác thực.
- Vietnamese Medical Fake News Dataset: Đây là nguồn dữ liệu chuyên biệt tập trung vào các thông tin sai lệch trong lĩnh vực y tế và sức khỏe. Việc tích hợp dữ liệu này cực kỳ quan trọng vì tin giả y tế thường sử dụng vốn từ vựng chuyên ngành và có mức độ nguy hại cao, đòi hỏi mô hình phải có khả năng phân biệt tinh vi giữa lời khuyên y khoa chuẩn xác và các thông tin sai lệch.

- Vietnamese Fake News Dataset 2 (Phiên bản mở rộng): Tập dữ liệu này cung cấp một lượng lớn các bản tin xác thực để cân bằng với các mẫu tin giả. Việc sử dụng một tập dữ liệu có tỉ lệ nhãn cân đối giúp hệ thống tránh được hiện tượng thiên kiến (bias), đảm bảo khả năng nhận diện tin thật và tin giả có độ chính xác tương đương nhau khi triển khai thực tế.

Việc sử dụng tổ hợp các tập dữ liệu mở này không chỉ giúp gia tăng số lượng mẫu huấn luyện lên hàng chục nghìn bản tin, mà còn giúp các mô hình học sâu như PhoBERT và thuật toán Logistic Regression đạt được khả năng tổng quát hóa tốt hơn. Điều này giúp hệ thống giữ được độ ổn định khi tiếp cận với các bản tin có nội dung biến đổi linh hoạt và ngữ cảnh phức tạp trên không gian mạng hiện nay.

3.3.2. Quy trình tiền xử lý dữ liệu

Quy trình tiền xử lý của hệ thống được thiết kế theo cấu trúc đa tầng, chia thành ba giai đoạn chính: xử lý dữ liệu huấn luyện, chuẩn hóa đặc trưng và xử lý dữ liệu thực tế khi suy luận. Việc chuẩn hóa này đảm bảo tính thống nhất về định dạng và tối ưu hóa khả năng học máy cho các mô hình.

a. Tiền xử lý dữ liệu huấn luyện (Offline Pre-processing)

Trong giai đoạn xây dựng tập huấn luyện, hệ thống tập trung vào việc hợp nhất các nguồn dữ liệu không đồng nhất từ các định dạng CSV, Excel và JSON thành một cấu trúc dữ liệu sạch và thống nhất. Các tệp dữ liệu từ nhiều nguồn khác nhau như "Medical dataset" hay "Fake News Vietnamese Dataset" được quy đổi về schema chung bao gồm hai trường thông tin cốt lõi là text (nội dung) và label (nhãn xác thực). Tại đây, các nhãn định tính hoặc ký hiệu riêng biệt được ánh xạ đồng nhất về hệ giá trị số, cụ thể là nhãn 0 cho tin thật và nhãn 1 cho các mẫu tin giả hoặc tin đồn. Đối với các tập dữ liệu có cấu trúc phức tạp như "VFND" (định dạng JSON), hệ thống áp dụng thuật toán quét đệ quy để trích xuất chính xác phần nội dung và tiêu đề, đảm bảo không bỏ sót thông tin quan trọng.

Sau khi hợp nhất, tập dữ liệu trải qua quy trình làm sạch văn bản chuyên sâu nhằm loại bỏ các yếu tố gây nhiễu cho mô hình. Hệ thống tự động rà soát và khử trùng lặp nội dung bài viết, đồng thời loại bỏ các bản ghi có độ dài quá ngắn (dưới 20 ký tự) do không chứa đủ thông tin để phân tích ngữ cảnh. Các kỹ thuật xử lý ngôn ngữ dựa trên biểu thức chính quy (Regex) được sử dụng để chuẩn hóa khoảng trắng và các ký tự đặc biệt. Để triệt tiêu sự thiên kiến (bias) có thể phát sinh từ thứ tự các nguồn dữ liệu, một bước xáo trộn ngẫu nhiên (Shuffling) được thực hiện trước khi lưu trữ dữ liệu dưới dạng tập tin CSV hợp nhất, sẵn sàng cho các bước huấn luyện chuyên sâu.

b. Tiền xử lý đặc trưng cho mô hình PhoBERT (Feature-level Pre-processing)

Giai đoạn này đảm nhận nhiệm vụ chuyển đổi văn bản tự nhiên sang định dạng vector số phù hợp với kiến trúc mạng nơ-ron của mô hình PhoBERT. Dữ liệu sạch sau khi hợp nhất được phân tách theo tỷ lệ 80% cho quá trình huấn luyện và 20% cho quá trình kiểm thử. Nhằm duy trì tính khách quan, kỹ thuật Stratified Split được áp dụng để đảm bảo tỷ lệ phân bố giữa lớp tin thật và tin giả trong hai tập con luôn tương đương với tập dữ liệu gốc, giúp mô hình tránh được hiện tượng mất cân bằng lớp.

Quá trình mã hóa đặc trưng (Tokenization) sử dụng bộ thư viện PhoBERT Tokenizer để thực hiện tách từ và gán mã số. Hệ thống áp dụng tham số max_length=256, kết hợp với các kỹ thuật cắt ngắn câu (Truncation) và bù thêm chuỗi rỗng (Padding) cho các câu không đủ độ dài. Kết quả của quá trình này là các mảng dữ liệu input_ids và attention_mask có kích thước cố định, giúp tối ưu hóa luồng dữ liệu trên các thiết bị tính toán phần cứng và đảm bảo mô hình có thể nắm bắt được các đặc trưng ngữ nghĩa trong một không gian vector nhất quán.

c. Tiền xử lý trong giai đoạn suy luận

Khi hệ thống vận hành thực tế, văn bản đầu vào từ người dùng được xử lý qua một quy trình tức thời nhằm đảm bảo sự tương thích tuyệt đối với các mô hình đã huấn luyện. Bước đầu tiên và quan trọng nhất là việc tách từ tiếng Việt thông qua công cụ ViTokenizer để nhận diện chính xác các từ ghép, giữ vững cấu trúc ngữ pháp đặc thù của ngôn ngữ. Điều này giúp lớp embedding của mô hình truy xuất được đúng ngữ nghĩa thay vì chỉ xử lý các từ đơn lẻ.

Tiếp theo, văn bản được làm sạch thông qua module chuẩn hóa tổng quát để xử lý các lỗi trình bày và khoảng trắng dư thừa. Cuối cùng, dữ liệu được đưa qua bộ mã hóa với cấu hình tham số tương tự như giai đoạn huấn luyện (truncation=True, max_length=256). Sự đồng bộ hóa chặt chẽ giữa quy trình tiền xử lý lúc huấn luyện và lúc suy luận là yếu tố tiên quyết giúp hệ thống đưa ra các dự đoán chính xác và ổn định đối với các thông tin biến động liên tục trên không gian mạng.

3.3.3. Module Phân tích đặc trưng văn phong

Trong khi các mô hình học sâu tập trung vào việc hiểu ngữ nghĩa phức tạp, module phân tích đặc trưng văn phong hướng tới việc nhận diện các dấu hiệu rủi ro xuất hiện trên bề mặt văn bản. Tin giả thường có xu hướng sử dụng ngôn từ kích động, giật gân, hoặc các cấu trúc câu đặc thù nhằm thu hút sự chú ý. Module này sử dụng thuật toán Logistic Regression kết hợp với kỹ thuật TF-IDF để khai thác các đặc trưng từ vựng và phong cách viết một cách hiệu quả.

a. Kỹ thuật trích xuất đặc trưng TF-IDF

Để máy tính có thể xử lý văn bản, hệ thống thực hiện chuyển đổi dữ liệu thô sang dạng vector số thông qua kỹ thuật TF-IDF. Kỹ thuật này không chỉ đếm tần suất xuất hiện của từ trong một bản tin (TF) mà còn đánh giá mức độ quan trọng của từ đó trong toàn bộ tập dữ liệu (IDF).

- Tần suất từ (Term Frequency – TF): Đo lường mức độ xuất hiện của từ 't' trong văn bản 'd':

$$\mathrm{tf}(t,d) = \frac{f_{t,d}}{\sum_k f_{k,d}}$$

- Tần suất nghịch đoạn (Inverse Document Frequency – IDF): Giảm trọng số của các từ xuất hiện quá phổ biến và tăng trọng số cho các từ mang tính đặc trưng.

$$\mathrm{Idf}(t) = \log \frac{N}{df_t}$$

Trong đó N là tổng số tài liệu và dft là số tài liệu chứa từ t.

Trọng số cuối cùng $\mathrm{tfidf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t)$ giúp hệ thống trích xuất được các bộ từ khóa (unigrams) và cụm từ (bigrams) có khả năng phân tách cao giữa tin thật và tin giả. Các vector đặc trưng này sau đó được sử dụng làm đầu vào cho mô hình phân loại tuyến tính.

Trong bối cảnh phát hiện tin giả, TF-IDF giúp hệ thống lọc bỏ các "từ dừng" (stop words) vô nghĩa và làm nổi bật các từ khóa có trọng số cao – thường là các danh từ riêng hoặc động từ mạnh mang tính dẫn dắt dư luận. Bằng cách biểu diễn văn bản dưới dạng các vector không gian nhiều chiều, hệ thống có thể xác định được các mẫu từ vựng thường xuyên xuất hiện trong các nhóm tin tức giả mạo đã được gán nhãn trước đó.

b. Thuật toán phân loại Logistic Regression

Sau khi dữ liệu được vector hóa, thuật toán Logistic Regression (Hồi quy Logistic) được sử dụng để thực hiện nhiệm vụ phân loại nhị phân. Lý do lựa chọn thuật toán này xuất phát từ tính hiệu quả cao đối với dữ liệu văn bản có số lượng đặc trưng lớn và khả năng cung cấp kết quả dưới dạng xác suất (Probability) một cách minh bạch.

Mô hình thực hiện tính toán tổng trọng số của các đặc trưng đầu vào thông qua hàm Sigmoid để đưa ra giá trị đầu ra nằm trong khoảng từ 0 đến 1. Giá trị này đại diện cho mức độ tin cậy của bản tin: các giá trị tiến gần về 0 tương ứng với văn phong báo

chí chuẩn mực, trong khi các giá trị tiến gần về 1 chỉ thị các dấu hiệu bất thường về văn phong thường thấy trong tin giả.

Mô hình tính toán xác suất một bản tin là tin giả (y=1) dựa trên vector đặc trưng x thông qua hàm Sigmoid:

$$P(y = 1 \mid x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$$

Trong đó, w là ma trận trọng số được học trong quá trình huấn luyện, đại diện cho mức độ ảnh hưởng của từng từ khóa đối với khả năng bản tin đó là giả mạo.

c. Vai trò của Module trong hệ thống đa tầng

Module Logistic Regression đóng vai trò là "lớp lọc văn phong" đầu tiên trong hệ thống. Ưu điểm lớn nhất của module này là tốc độ xử lý nhanh và khả năng giải thích rõ ràng (Interpretability). Thông qua việc phân tích các trọng số w sau khi huấn luyện, hệ thống có thể chỉ ra chính xác những từ ngữ nào đang góp phần làm tăng chỉ số rủi ro của bản tin.

3.3.4. Module Phân loại ngữ nghĩa sâu (PhoBERT)

Trong hệ thống xác thực tin tức đa tầng, nếu Logistic Regression đóng vai trò phân tích các dấu hiệu bề mặt thì module PhoBERT là thành phần cốt lõi đảm nhiệm việc khai thác ngữ nghĩa sâu và mối quan hệ ngữ cảnh phức tạp. Hệ thống thực hiện tinh chỉnh (Fine-tuning) mô hình vinai/phobert-base – một kiến trúc dựa trên RoBERTa được huấn luyện chuyên biệt cho tiếng Việt để giải quyết bài toán phân loại nhị phân tin thật và tin giả.

a. Cơ chế hoạt động và mô hình hóa xác suất

Hoạt động của module dựa trên nguyên lý học chuyển đổi (Transfer Learning), trong đó các tri thức ngôn ngữ khổng lồ từ mô hình gốc được áp dụng vào bài toán phân loại nhị phân tin thật và tin giả. Sau khi văn bản được mã hóa và đi qua các lớp Transformer của PhoBERT, mô hình trích xuất vector đặc trưng tại vị trí đặc biệt để đại diện cho toàn bộ ngữ cảnh của bản tin đầu vào. Tại lớp cuối cùng của mạng nơ-ron, một tầng tuyến tính được sử dụng để tính toán các giá trị đầu ra (logits) cho hai nhãn tương ứng.

Để chuyển đổi các giá trị này sang dạng xác suất có thể định lượng, hệ thống áp dụng hàm Softmax. Hàm này đóng vai trò chuẩn hóa các giá trị đầu ra thô thành một phân phối xác suất nằm trong khoảng [0, 1], giúp hệ thống xác định mức độ tin cậy của dự đoán. Công thức tổng quát của hàm Softmax được biểu diễn như sau:

$$p_i = \text{softmax}(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

Trong đó, z_i là giá trị logit của lớp thứ i, và $\sum e^{z_j}$ là tổng số mũ của tất cả các lớp đầu ra. Trong dự án này, hệ thống trích xuất xác suất tại vị trí tương ứng với nhãn tin giả p_{fake} để làm chỉ số đo lường rủi ro nội dung. Kết quả này phản ánh cái nhìn định tính của mô hình học sâu về tính xác thực của thông tin dựa trên những quy luật ngôn ngữ đã được học.

b. Quy trình huấn luyện và tối ưu hóa trọng số

Quá trình huấn luyện module được thực hiện thông qua việc tinh chỉnh các trọng số của mô hình trên tập dữ liệu đã gán nhãn chuẩn mực. Hệ thống sử dụng thuật toán tối ưu AdamW với tốc độ học 2×10^{-5} trong vòng 03 chu kỳ (epochs). Việc thiết lập số chu kỳ huấn luyện thấp là một chiến lược kỹ thuật nhằm đạt được độ chính xác tối ưu trên tập dữ liệu tiếng Việt mà không gây ra hiện tượng quá khớp (Overfitting), đảm bảo mô hình giữ được khả năng tổng quát hóa khi tiếp nhận các bản tin mới chưa từng xuất hiện trong quá trình học.

Trong mỗi đợt xử lý dữ liệu, sai số giữa xác suất dự đoán và nhãn thực tế được đo lường thông qua hàm mất mát Cross-Entropy. Thông qua cơ chế lan truyền ngược, các trọng số trong mạng nơ-ron sẽ được cập nhật liên tục để tối thiểu hóa sai số này. Sau khi hoàn tất huấn luyện, mô hình được kiểm chứng trên tập dữ liệu độc lập để đánh giá hiệu năng qua các chỉ số Accuracy và F1-score, sau đó được lưu trữ dưới định dạng mô hình đã đóng gói để phục vụ giai đoạn vận hành thực tế của hệ thống.

c. Vai trò trong cơ chế quyết định tổng hợp

Trong kiến trúc tổng thể, PhoBERT giữ vị trí trọng yếu khi đóng góp 50% trọng số vào chỉ số rủi ro cuối cùng. Vai trò của module không chỉ dừng lại ở việc đưa ra một con số dự đoán độc lập mà còn là dữ liệu đầu vào cốt lõi để phối hợp cùng các thành phần khác. Kết quả rủi ro ngữ nghĩa từ PhoBERT sẽ được kết hợp với chỉ số văn phong từ Logistic Regression và bằng chứng đối soát từ Search API để tạo thành một hệ thống đánh giá đa chiều.

3.3.5. Module Kiểm chứng chéo và Đối soát nguồn tin

Module Kiểm chứng chéo đóng vai trò là tầng xác thực thực chứng, đảm bảo hệ thống không chỉ dựa vào các dự đoán nội tại của trí tuệ nhân tạo mà còn bám sát vào các bằng chứng thực tế từ mạng lưới báo chí chính thống. Vai trò cốt lõi của module này là tìm kiếm các nguồn tin hỗ trợ hoặc bác bỏ nội dung đầu vào, từ đó cung cấp một chỉ số bằng chứng khách quan để hiệu chỉnh kết luận cuối cùng.

a. Quy trình thu thập và xử lý bằng chứng ngoại vi

Quy trình thực hiện bắt đầu bằng việc trích xuất các tuyên bố chủ chốt và từ khóa sự kiện từ văn bản đầu vào. Hệ thống sử dụng các giao diện lập trình ứng dụng để thực hiện truy vấn thời gian thực trên các nền tảng tìm kiếm quy mô lớn. Luồng xử lý dữ liệu được thực hiện qua các giai đoạn chặt chẽ:

- Truy vấn và sàng lọc dữ liệu: Hệ thống gửi các đoạn văn bản quan trọng làm câu lệnh tìm kiếm, sau đó thu thập danh sách kết quả gồm tiêu đề, đoạn trích dẫn và địa chỉ liên kết. Các kết quả này được chuẩn hóa tên miền và đánh giá độ liên quan dựa trên ngưỡng tương đồng tối thiểu để loại bỏ các thông tin nhiễu hoặc không liên quan đến sự kiện.
- Khai thác nội dung chuyên sâu: Để tăng cường độ chính xác, hệ thống tự động chọn lọc các nguồn tin có độ tương đồng cao nhất để thực hiện thu thập dữ liệu toàn văn. Điều này cho phép hệ thống phân tích sâu vào ngữ cảnh bài viết thay vì chỉ dựa vào các đoạn tóm tắt ngắn từ công cụ tìm kiếm.
- Phân tích sự tương đồng và thái độ: Hệ thống thực hiện so sánh các tuyên bố đầu vào với từng nguồn bằng chứng thông qua các tiêu chí: độ tương đồng ngữ nghĩa, mức độ trùng lặp từ khóa và phân tích thái độ của nguồn tin đối với vấn đề đang xét (ủng hộ, phản đối hoặc trung lập).

b. Thuật toán tính toán trọng số bằng chứng

Mỗi nguồn tin được thu thập sẽ đóng góp vào tổng điểm bằng chứng thông qua một công thức trọng số đa thành phần, đảm bảo tính khách quan và chiều sâu của thông tin:

$$\text{weight}_{ev} = \text{sign}_{st} \times \text{rel}_{sem} \times \text{conf}_{st} \times \text{score}_{temp} \times \text{weight}_{dom}$$

Trong đó:

- sign_{st}: Chỉ số thái độ (nhận giá trị dương nếu hỗ trợ và âm nếu bác bỏ).
- rel_{sem}: Độ liên quan về ngữ nghĩa và các từ khóa cốt lõi.
- conf_{st}: Độ tin cậy của mô hình phân tích thái độ.
- score_{temp}: Điểm thời gian, ưu tiên các tin tức trùng khớp thời gian và giảm giá trị của các thông tin quá lệch mốc sự kiện.
- weight_{dom}: Trọng số uy tín của tên miền, được xác định dựa trên danh sách các nguồn tin xác thực và báo chí chính thống.

Tổng các trọng số bằng chứng sau đó được chuẩn hóa thông qua hàm Sigmoid để chuyển đổi về khoảng giá trị [0, 1] nhằm đồng bộ hóa với các module AI khác:

$$Score_{evidence} = \frac{1}{1 + e^{-\sum \text{weight}_{ev}}}$$

Chỉ số này càng tiến gần về 1 thể hiện bằng chứng hỗ trợ cho bản tin càng mạnh mẽ, ngược lại nếu tiến gần về 0 sẽ cảnh báo về sự thiếu hụt bằng chứng hoặc tồn tại sự bác bỏ trực tiếp từ thực tế báo chí.

c. Vai trò và tương tác trong hệ thống tổng quát

Kết quả từ Module Kiểm chứng chéo không chỉ cung cấp chỉ số định lượng mà còn trả về các dữ liệu định tính như danh sách các nguồn tin tin cậy, các nguồn chưa xác thực và đặc biệt là các thông tin đính chính chính thức. Những dữ liệu này là thành phần cốt yếu để tầng suy luận ngôn ngữ tạo ra các lời giải thích minh bạch cho người dùng.

Trong cơ chế hợp nhất rủi ro tổng thể, điểm bằng chứng đóng góp trọng số đáng kể vào kết luận cuối cùng. Một điểm đặc thù mang tính an toàn cao của hệ thống là Cơ chế ghi đè ưu tiên: nếu quá trình đối soát phát hiện các nguồn tin đính chính trực tiếp từ các cơ quan thông tấn uy tín, hệ thống sẽ tự động thiết lập chỉ số rủi ro lên mức tối đa (0.95) bất kể kết quả từ các mô hình học máy. Điều này giúp hệ thống đạt được sự cân bằng giữa khả năng tư duy của trí tuệ nhân tạo và tính xác thực tuyệt đối từ dữ liệu thực tế tại thời điểm truy vấn.

3.4. Thuật toán tổng hợp điểm và Cơ chế ra quyết định

Sau khi bản tin trải qua các tầng phân tích độc lập, hệ thống cần một cơ chế hợp nhất các chỉ số định lượng và định tính để đưa ra kết luận cuối cùng. Thuật toán tổng hợp được thiết kế theo mô hình biểu quyết có trọng số, kết hợp giữa khả năng nhận diện ngôn ngữ của AI và tính thực chứng từ dữ liệu báo chí.

3.4.1. Phương pháp tính toán trọng số đa tầng

Chỉ số rủi ro tổng hợp được tính toán dựa trên sự đóng góp của ba thành phần cốt lõi: mô hình phân loại nội dung (PhoBERT), mô hình phân tích văn phong (Logistic Regression) và chỉ số bằng chứng từ tầng đối soát ngoại vi. Công thức tổng quát được thiết lập như sau:

$$Final_Risk = w_1 \cdot p_{phobert} + w_2 \cdot p_{lr} + w_3 \cdot (1 - Score_{evidence})$$

Trong đó, các hệ số trọng số được xác định dựa trên độ tin cậy thực nghiệm của từng module:

- $w_1 = 0.5$ (Trọng số PhoBERT): Chiếm tỷ trọng lớn nhất do khả năng hiểu ngữ cảnh sâu và độ chính xác cao nhất trong các mô hình AI.

- $w_2 = 0.1$ (Trọng số Logistic Regression): Đóng vai trò hỗ trợ nhận diện các dấu hiệu bất thường về mặt hình thức và từ vựng giật gân.
- $w_3 = 0.4$ (Trọng số Bằng chứng): Đóng vai trò hiệu chỉnh thực tế. Nếu bằng chứng đối soát càng cao, thành phần rủi ro này càng giảm, giúp bảo vệ các tin tức chính thống có văn phong đặc biệt.

3.4.2. Cơ chế xử lý ưu tiên và Ghi đè (Override Logic)

Nhằm tối ưu hóa tính an toàn và giảm thiểu sai sót đối với các loại tin giả gây nguy hại nghiêm trọng, hệ thống thiết lập một cơ chế ưu tiên dựa trên các nguồn tin đính chính chính thức. Đây là logic quan trọng giúp hệ thống vượt qua các giới hạn về mặt cảm tính của các mô hình học máy.

Trong quá trình đối soát, nếu Module Kiểm chứng chéo phát hiện sự hiện diện của các nguồn tin mang tính chất bác bỏ hoặc đính chính (Debunk) từ các cơ quan thông tấn uy tín trong danh sách trắng (Whitelist), hệ thống sẽ kích hoạt lệnh ghi đè. Lúc này, mọi tính toán trọng số từ các mô hình AI sẽ được tạm ngưng và chỉ số rủi ro tổng hợp sẽ được thiết lập mặc định ở mức 0.95. Cơ chế này đảm bảo rằng khi đã có bằng chứng xác thực về việc thông tin là giả mạo từ các nguồn tin cậy, hệ thống sẽ ngay lập tức đưa ra cảnh báo ở mức cao nhất cho người dùng.

CHƯƠNG IV: THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Kết quả huấn luyện và Đánh giá mô hình AI

4.1.1. Đánh giá mô hình Logistic Regression

Mô hình Logistic Regression kết hợp với kỹ thuật trích xuất đặc trưng TF-IDF được triển khai nhằm nhận diện các dấu hiệu tin giả thông qua đặc trưng văn phong và từ vựng bề mặt. Kết quả thực nghiệm trên tập dữ liệu kiểm thử cho thấy mô hình đạt được hiệu năng ổn định, đóng vai trò là một lớp lọc quan trọng trong hệ thống đa tầng.

a. Phân tích chỉ số định lượng

Thông qua bảng báo cáo phân loại (Classification Report), các chỉ số đánh giá mô hình được ghi nhận cụ thể như sau:

```
Accuracy: 0.9130
F1-score: 0.8531

Classification Report:
              precision    recall  f1-score   support

           0       0.96      0.92      0.94      3304
           1       0.81      0.90      0.85      1282

    accuracy                           0.91      4586
   macro avg       0.88      0.91      0.90      4586
weighted avg       0.92      0.91      0.91      4586
```

Hình 3: Báo cáo phân loại mô hình Logistic Regression

Dựa trên kết quả thu được từ bảng báo cáo phân loại, mô hình Logistic Regression đã thể hiện năng lực phân loại ấn tượng với độ chính xác tổng thể (Accuracy) đạt mức 91.30%. Con số này cho thấy mô hình có khả năng nhận diện đúng đại đa số các mẫu tin tức trong tập kiểm thử. Tuy nhiên, trong bài toán đặc thù về phát hiện tin giả, chỉ số F1-Score đạt mức 0.85 (tương đương 85% cho nhãn tin giả) và 90% cho trung bình cộng các nhãn là minh chứng xác thực hơn cho sự ổn định của hệ thống, khẳng định rằng mô hình không bị thiên kiến và có khả năng xử lý tốt sự mất cân bằng giữa các lớp dữ liệu.

Đi sâu vào phân tích các chỉ số thành phần cho nhãn tin giả, giá trị Recall đạt mức 90% là một kết quả đặc biệt quan trọng. Điều này có nghĩa là trong 100 tin giả thực tế, mô hình đã thành công phát hiện và đưa ra cảnh báo đối với 90 trường

hợp. Trong nghiệp vụ kiểm chứng tin tức, việc ưu tiên chỉ số Recall giúp hệ thống giảm thiểu tối đa nguy cơ bỏ sót các nội dung độc hại, từ đó bảo vệ người dùng trước các luồng thông tin sai lệch một cách hiệu quả nhất.

Mặt khác, chỉ số Precision ở mức 81% cho nhãn tin giả phản ánh sự đánh đổi cần thiết giữa độ nhạy và độ chính xác. Mặc dù có một tỷ lệ nhỏ các tin tức chính thống bị nhận diện nhầm do sử dụng văn phong có nhiều nét tương đồng với tin giả, nhưng tỷ lệ 81% vẫn đảm bảo rằng phần lớn các cảnh báo từ mô hình đều có cơ sở khoa học và độ tin cậy cao. Sự kết hợp hài hòa giữa các chỉ số này đã khẳng định Logistic Regression là một lớp lọc văn phong mạnh mẽ, đóng vai trò nền tảng trong quy trình xác thực đa tầng của toàn hệ thống.

b. Phân tích ma trận nhầm lẫn (Confusion Matrix)

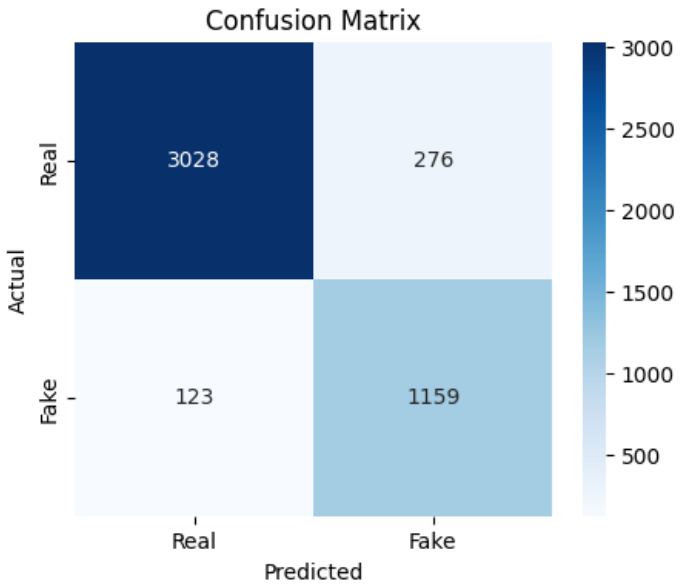

Hình 4: Biểu đồ ma trận nhầm lẫn mô hình Logistic Regression

Ma trận nhầm lẫn cung cấp cái nhìn chi tiết về các trường hợp dự đoán đúng và các sai sót của mô hình trên tổng số 4.586 mẫu kiểm thử:

- Dự đoán đúng (True Positive & True Negative): Mô hình đã nhận diện chính xác 3.028 mẫu tin thật (Real) và 1.159 mẫu tin giả (Fake).
- Dương tính giả (False Positive - 276 mẫu): Có 276 mẫu tin thật bị mô hình đánh nhầm là tin giả. Điều này có thể giải thích do một số tin tức chính thống sử dụng văn phong gây chú ý hoặc các từ khóa trùng lặp với tập tin giả.
- Âm tính giả (False Negative - 123 mẫu): Đây là các trường hợp tin giả bị lọt qua lớp lọc văn phong. Tuy nhiên, tỷ lệ này khá thấp (~2.6% trên tổng mẫu), khẳng định độ tin cậy của mô hình.

c. Đánh giá chung

Kết quả thực nghiệm cho thấy Logistic Regression hoạt động cực kỳ hiệu quả trong việc nhận diện các mẫu hình ngôn ngữ đặc trưng của tin giả. Mặc dù chỉ số Precision của nhãn tin giả (81%) thấp hơn so với nhãn tin thật (96%), nhưng với mục tiêu ưu tiên "thà lầm còn hơn sót" trong việc phát hiện tin độc hại, việc duy trì chỉ số Recall cao là một thành công về mặt nghiệp vụ.

Sự nhầm lẫn giữa các mẫu tin thật và tin giả ở lớp này sẽ tiếp tục được hiệu chỉnh và tối ưu hóa ở các tầng phân tích sâu hơn (PhoBERT) và tầng đối soát thực tế (Search API), nhằm đảm bảo kết luận cuối cùng của hệ thống đạt độ chính xác tối ưu.

4.1.2. Đánh giá mô hình PhoBERT

Module phân loại ngữ nghĩa sâu sử dụng kiến trúc PhoBERT đã thể hiện sự vượt trội về khả năng hiểu ngữ cảnh tiếng Việt, mang lại kết quả tối ưu cho hệ thống xác thực tin tức. Bằng việc tinh chỉnh (Fine-tuning) mô hình trên tập dữ liệu thực nghiệm, PhoBERT đã giải quyết hiệu quả những giới hạn của các mô hình học máy truyền thống trong việc nhận diện các thủ đoạn biến đổi nội dung tinh vi.

a. Phân tích chỉ số định lượng

```
Evaluating: 100%|██████████| 574/574 [01:33<00:00,  6.13it/s]
Accuracy: 0.9483209768861753
F1-score: 0.9029086439983613

Classification Report:
              precision    recall  f1-score   support

           0     0.9475    0.9827    0.9648      3304
           1     0.9508    0.8596    0.9029      1282

    accuracy                         0.9483      4586
   macro avg     0.9491    0.9212    0.9338      4586
weighted avg     0.9484    0.9483    0.9475      4586
```

Hình 5: Báo cáo phân loại mô hình PhoBERT

Kết quả từ bảng báo cáo phân loại cho thấy mô hình PhoBERT đạt độ chính xác tổng thể (Accuracy) ấn tượng ở mức 94.83%. Chỉ số F1-score đạt xấp xỉ 90.30% cho nhãn tin giả và 93.38% cho giá trị trung bình cộng (Macro average), khẳng định năng lực phân loại đồng đều và cực kỳ ổn định trên cả hai nhóm dữ liệu.

Điểm sáng nhất của PhoBERT nằm ở chỉ số Precision cho nhãn tin giả đạt mức 95.08%. Điều này có ý nghĩa cực kỳ quan trọng trong vận hành thực tế: khi hệ thống sử dụng PhoBERT để cảnh báo một bản tin là giả mạo, độ tin cậy của lời cảnh báo đó đạt mức gần như tuyệt đối. So với mô hình Logistic Regression, PhoBERT đã cải thiện đáng kể khả năng phân biệt, giúp giảm thiểu tối đa các trường hợp tin thật bị gán nhãn nhầm (Dương tính giả). Bên cạnh đó, chỉ số Recall duy trì ở mức 85.96% cho thấy mô hình vẫn giữ được sự nhạy bén cần thiết để phát hiện đại đa số các thông tin sai lệch dựa trên ngữ nghĩa sâu của văn bản.

b. Phân tích ma trận nhầm lẫn

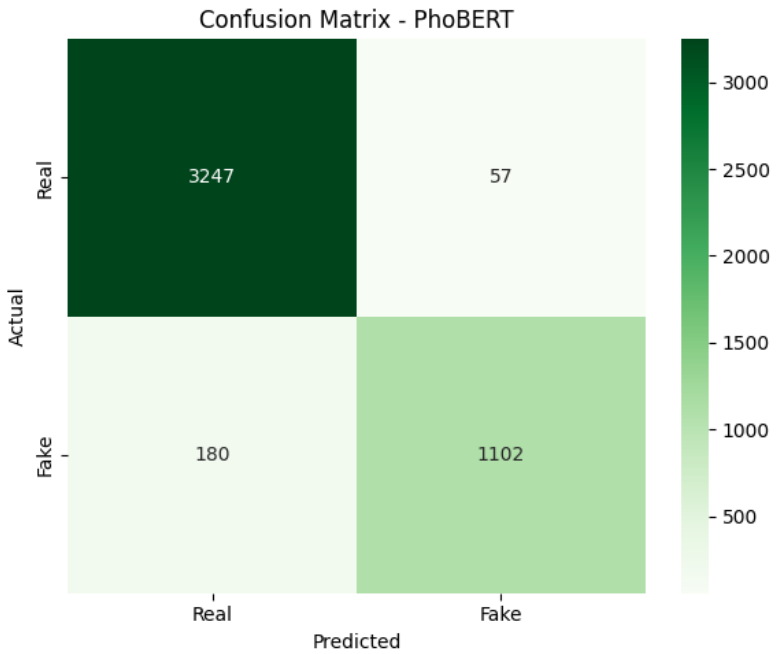

Hình 6: Ma trận nhầm lẫn mô hình PhoBERT

Ma trận nhầm lẫn minh chứng cho sức mạnh mã hóa thông tin của kiến trúc Transformer khi số lượng dự đoán đúng chiếm tỷ lệ áp đảo. Cụ thể, mô hình đã nhận diện chính xác 3.247 mẫu tin thật và 1.102 mẫu tin giả trên tổng số mẫu kiểm thử. Sự cải tiến rõ rệt nhất nằm ở việc giảm thiểu số ca dương tính giả xuống chỉ còn 57 trường hợp (so với 276 ca của mô hình trước đó). Sự chênh lệch này khẳng định rằng khi được huấn luyện về ngữ cảnh, mô hình có khả năng loại bỏ các hiểu lầm do văn phong gây ra để tập trung vào bản chất nội dung.

Mặc dù vẫn tồn tại 180 mẫu tin giả bị mô hình nhận diện nhầm là tin thật (Âm tính giả), nhưng khi kết hợp trong hệ thống đa tầng, những lỗ hổng này sẽ tiếp tục được bù đắp bởi module đối soát thực tế từ công cụ tìm kiếm. Nhìn chung, PhoBERT đóng vai trò là chốt chặn đáng tin cậy nhất về mặt định tính, cung cấp cơ sở vững chắc

cho chỉ số rủi ro tổng hợp của hệ thống, giúp đưa ra những kết luận có độ chính xác cao và thuyết phục người sử dụng.

4.3. Triển khai ứng dụng và Giao diện thực tế

Sau khi hoàn tất quá trình huấn luyện và đánh giá các mô hình thành phần, hệ thống đã được triển khai dưới dạng một ứng dụng web hoàn chỉnh. Mục tiêu của giao diện là tối giản hóa các thao tác kỹ thuật phức tạp, giúp người dùng phổ thông có thể tiếp cận kết quả phân tích tin tức một cách nhanh chóng và trực quan nhất.

a. Kiến trúc triển khai ứng dụng

Ứng dụng được triển khai dựa trên kiến trúc Client-Server hiện đại. Phần giao diện (Frontend) được thiết kế tối giản, tập trung vào khả năng hiển thị biểu đồ và dữ liệu đối soát. Phần xử lý trung tâm (Backend) tích hợp các mô hình PhoBERT, Logistic Regression và các dịch vụ truy vấn thông tin bên ngoài qua các giao diện lập trình ứng dụng. Việc tách biệt này đảm bảo hệ thống có thể mở rộng và cập nhật các mô hình AI trong tương lai mà không làm ảnh hưởng đến trải nghiệm người dùng.

b. Giao diện trang chủ và Nhập liệu

Giao diện chính của hệ thống được thiết kế với trung tâm là khu vực tiếp nhận thông tin. Người dùng có hai lựa chọn chính: sao chép nội dung văn bản trực tiếp hoặc cung cấp đường dẫn bài báo cần kiểm chứng. Hệ thống cung cấp các chỉ dẫn rõ ràng để người dùng có thể bắt đầu quy trình xác thực chỉ với một thao tác nhấp chuột.

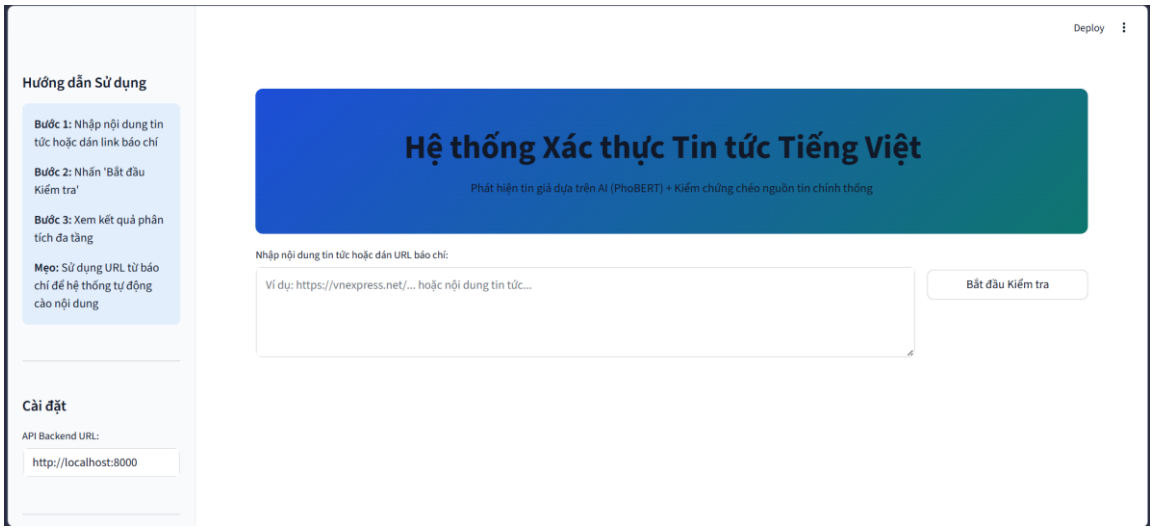

Hình 7: Giao diện trang chủ

c. Giao diện báo cáo kết quả tổng hợp

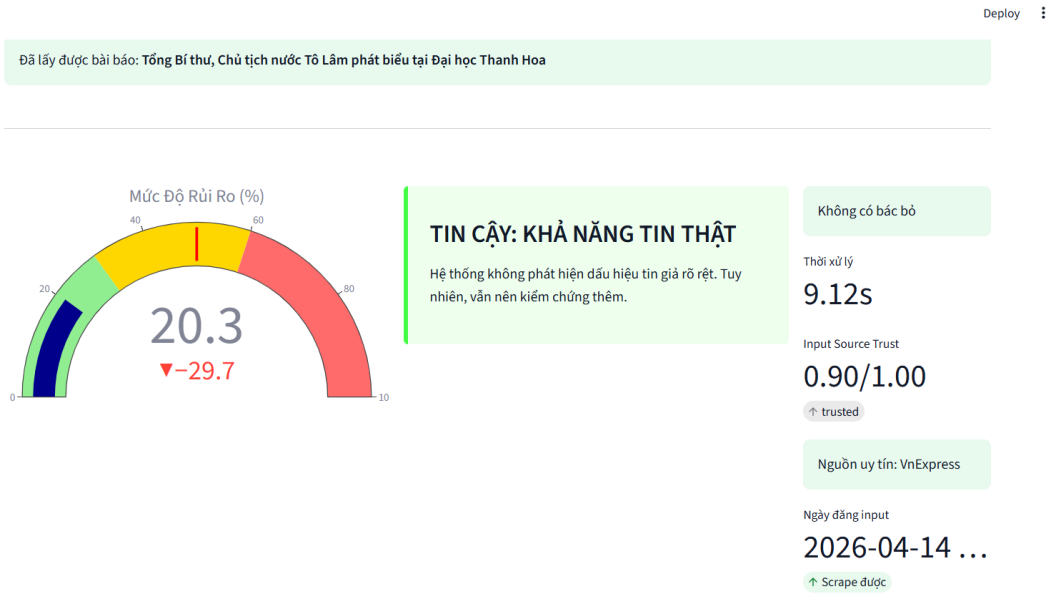

Hình 8: Giao diện báo cáo kết quả đánh giá tin tức

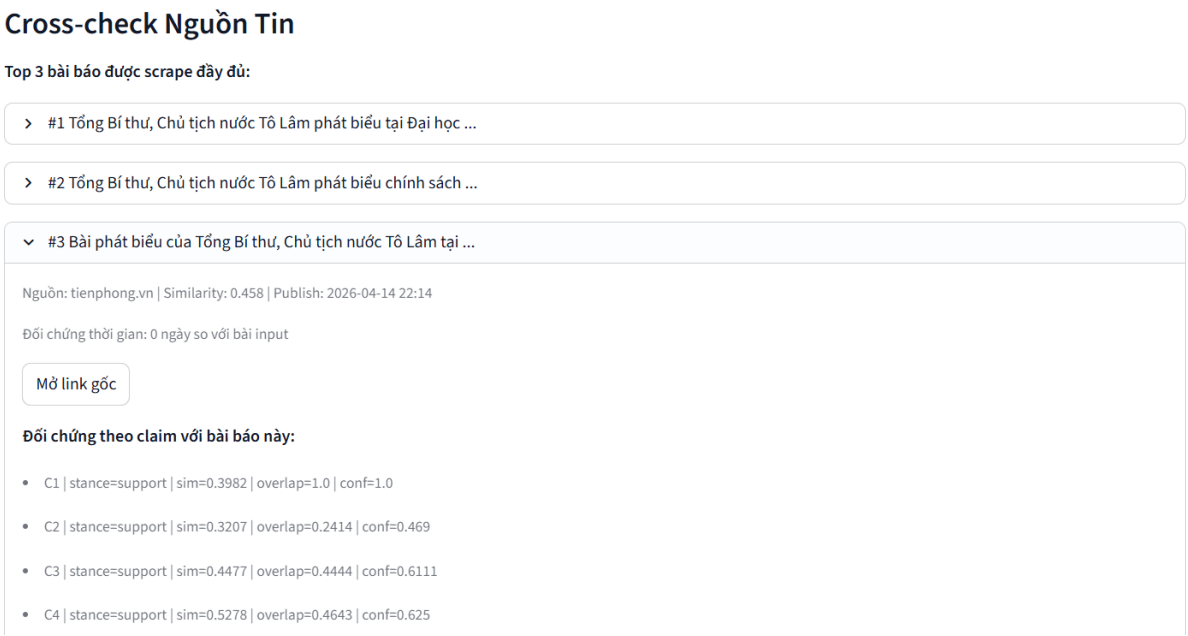

Hình 9: Kết quả kiểm chứng chéo ngoại vi

Đây là thành phần quan trọng nhất trong trải nghiệm người dùng, nơi kết quả từ thuật toán tổng hợp điểm được hiển thị.

- Chỉ số rủi ro trực quan: Mức độ tin cậy được biểu diễn thông qua các thang đo màu sắc từ Xanh (Tin cậy) đến Đỏ (Rủi ro cao), giúp người dùng nhận diện ngay lập tức bản chất của thông tin.

- Chi tiết bằng chứng đối soát: Hệ thống liệt kê danh sách các bài báo có độ tương đồng từ các nguồn tin uy tín cùng với tiêu đề và đoạn trích dẫn ngắn. Điều này giúp người dùng không chỉ nhận được kết luận từ AI mà còn có căn cứ thực tế để tự mình đánh giá lại thông tin.

d. Khả năng tương tác và Giải thích kết quả

Hình 10: Giao diện giải thích kết quả dự đoán

Hệ thống cung cấp thêm phần phân tích về các dấu hiệu bất thường trong văn phong và nội dung. Bằng cách bóc tách các từ ngữ có tính chất kích động hoặc chỉ ra sự thiếu hụt bằng chứng thực tế, hệ thống giúp người dùng nâng cao nhận thức và tư duy phản biện trước các luồng tin tức sai lệch. Toàn bộ thông tin được trình bày một cách có hệ thống, minh bạch hóa quy trình ra quyết định của các mô hình AI phía sau.

CHƯƠNG V: THẢO LUẬN VÀ HẠN CHẾ

5.1. Phân tích sự tương quan giữa các mô hình thành phần

Dựa trên kết quả thực nghiệm tại Chương 4, có thể thấy sự khác biệt rõ rệt về hiệu năng giữa các phương pháp tiếp cận. Mô hình Logistic Regression với đặc trưng TF-IDF đóng vai trò là một bộ lọc văn phong hiệu quả, đạt kết quả tốt trong việc nhận diện các tin tức có cấu trúc từ vựng bất thường. Tuy nhiên, mô hình này vẫn bộc lộ hạn chế khi đối mặt với các tin giả được viết lách trau chuốt, có cấu trúc tương đồng với báo chí chính thống.

Sự xuất hiện của PhoBERT đã giải quyết triệt để lỗ hổng này. Với khả năng mã hóa ngữ cảnh hai chiều, PhoBERT không chỉ nhìn vào từ vựng đơn lẻ mà hiểu được mối quan hệ giữa các mệnh đề, từ đó phát hiện ra các mâu thuẫn về mặt logic nội dung. Sự cải thiện về chỉ số Precision (tăng từ 81% lên hơn 95%) khi sử dụng PhoBERT minh chứng rằng việc hiểu ngữ nghĩa sâu là chìa khóa để giảm thiểu tỷ lệ "Dương tính giả", giúp hệ thống trở nên tin cậy hơn trong mắt người dùng.

5.2. Hạn chế và các thách thức kỹ thuật

Mặc dù đạt được những kết quả khả quan, quá trình thực nghiệm cũng chỉ ra các thách thức cần được giải quyết:

- Sự lệ thuộc vào hạ tầng bên ngoài: Việc phụ thuộc vào các API tìm kiếm và tốc độ phản hồi của các trang báo điện tử tạo ra sự không đồng nhất về thời gian xử lý. Trong một số trường hợp mạng không ổn định, độ trễ có thể gây ảnh hưởng đến trải nghiệm người dùng.
- Giới hạn của dữ liệu huấn luyện: Các mô hình AI vẫn có xu hướng dự đoán dựa trên các mẫu hình tin giả đã biết trong quá khứ. Với các thủ đoạn tin giả hoàn toàn mới hoặc các tin tức mang tính châm biếm (satire), hệ thống vẫn cần sự hỗ trợ đắc lực từ con người để tinh chỉnh lại trọng số đánh giá.
- Vấn đề tin giả đa phương tiện: Hiện tại hệ thống mới chỉ đáp ứng tốt yêu cầu đối với dữ liệu dạng văn bản. Đây là một hạn chế khách quan vì tin giả hiện nay đang có xu hướng chuyển dịch mạnh mẽ sang định dạng video ngắn và hình ảnh cắt ghép.

5.3. Bài học kinh nghiệm và Hướng phát triển

Từ những thảo luận trên, dự án rút ra bài học rằng việc kết hợp giữa AI định tính và dữ liệu đối soát thực chứng là hướng đi tối ưu để xây dựng niềm tin số. Trong tương lai, hệ thống cần được nâng cấp thông qua việc tối ưu hóa thuật toán cào dữ liệu bất đồng bộ nhằm giảm độ trễ, đồng thời mở rộng khả năng kiểm chứng trực tiếp trên các nền tảng mạng xã hội thông qua các tiện ích mở rộng để ngăn chặn tin giả ngay từ nguồn phát tán. Bên cạnh đó, việc xây dựng cơ chế lưu trữ kết quả kiểm chứng sẽ giúp tái sử dụng dữ liệu hiệu quả, giảm tải cho hệ thống và tạo tiền đề để đề xuất các luồng tin tức (news feed) an toàn từ các nguồn thông tấn uy tín, giúp người dùng chủ động tiếp cận thông tin sạch.

Hệ thống cũng hướng tới việc phát triển toàn diện các mô hình phân tích đa phương tiện để đối phó với vấn nạn tin giả dưới dạng hình ảnh và video Deepfake đang ngày càng tinh vi. Việc tích hợp cơ chế phản hồi từ cộng đồng và xây dựng cơ sở dữ liệu về các chiến dịch thông tin sai lệch theo thời gian thực sẽ biến ứng dụng không chỉ là một công cụ phân tích thuần túy mà còn là một lá chắn bảo vệ an ninh thông tin bền vững. Những cải tiến này không chỉ khắc phục các hạn chế hiện tại về tốc độ và phạm vi xử lý mà còn kiến tạo một hệ sinh thái kiểm chứng tin tức minh bạch, chủ động và có khả năng thích ứng cao với sự biến đổi không ngừng của môi trường internet.

KẾT LUẬN

Thông qua quá trình thực nghiệm và phân tích hệ thống chuyên sâu, nghiên cứu đã khẳng định tính khả thi và hiệu quả vượt trội của mô hình phân loại đa tầng trong nhiệm vụ xác thực tin tức ngôn ngữ tiếng Việt. Việc thiết lập một kiến trúc lai (hybrid architecture), kết hợp giữa khả năng biểu diễn ngôn ngữ sâu sắc của mô hình Transformer (PhoBERT) và sự nhạy bén trong việc bóc tách đặc trưng văn phong của thuật toán Logistic Regression, đã tạo ra một cơ chế kiểm chứng toàn diện. Kết quả ghi nhận tại chương thực nghiệm với độ chính xác trên 94% không chỉ minh chứng cho sức mạnh của việc khai thác ngữ nghĩa ngữ cảnh mà còn cho thấy đây là giải pháp tối ưu để nhận diện các thủ đoạn dàn dựng thông tin tinh vi – những yếu tố mà các phương pháp phân tích từ vựng truyền thống thường bỏ lỡ do giới hạn trong việc hiểu tính đa nghĩa và cấu trúc cú pháp phức tạp của tiếng Việt.

Đóng góp quan trọng nhất của hệ thống này nằm ở việc thiết lập thành công mối liên kết hữu cơ giữa năng lực dự đoán của trí tuệ nhân tạo và hệ thống bằng chứng thực chứng thời gian thực từ các nguồn tin chính thống. Giải pháp này đã khắc phục triệt để tính chất "hộp đen" (black-box) thường thấy trong các mô hình học sâu bằng cách minh bạch hóa quy trình ra quyết định. Thay vì chỉ cung cấp một kết luận xác suất đơn thuần, hệ thống trang bị cho người tiếp nhận thông tin các cơ sở đối soát cụ thể, tạo ra tính thuyết phục và độ tin cậy cao cho kết quả kiểm chứng. Điều này đóng vai trò quyết định trong việc xây dựng niềm tin của người dùng đối với các hệ thống hỗ trợ quyết định dựa trên AI.

Về mặt thực tiễn, thành công của hệ thống không chỉ dừng lại ở các chỉ số định lượng ấn tượng mà còn định hình một phương thức tiếp cận mới trong việc xây dựng các công cụ hỗ trợ cộng đồng. Trong bối cảnh chuyển đổi số mạnh mẽ và sự bùng nổ của các luồng dữ liệu phi cấu trúc, nghiên cứu đã góp phần quan trọng vào nỗ lực nâng cao tư duy phản biện và thiết lập một "hàng rào kỹ thuật" bảo vệ an ninh thông tin bền vững. Kết quả của nghiên cứu này kỳ vọng sẽ trở thành nền tảng định hướng cho các ứng dụng thực tế trong việc làm sạch môi trường thông tin mạng, góp phần xây dựng một không gian số minh bạch và an toàn hơn tại Việt Nam.

TÀI LIỆU THAM KHẢO

[1]. Lv, J., Gao, Y., Li, L., Shi, L., & Li, S. (2025). Multi-modal fake news detection: A comprehensive survey on deep learning technology, advances, and challenges. *Journal of King Saud University - Computer and Information Sciences*, *37*(306). https://doi.org/10.1007/s44443-025-00317-7

[2]. Raza, S., Paulen-Patterson, D., & Ding, C. (2025). Fake news detection: Comparative evaluation of BERT-like models and large language models with generative AI-annotated data. *Knowledge and Information Systems*. https://doi.org/10.1007/s10115-025-01234-5

[3]. Salve, R. R. (2025). *Fake news detection: Leveraging natural language processing and machine learning for reliable information verification* (Master's thesis). Rochester Institute of Technology.

[4]. Thota, A., Tilak, P., Ahluwalia, S., & Lohia, N. (2018). Fake news detection: A deep learning approach. *SMU Data Science Review*, *1*(3). https://scholar.smu.edu/datasciencereview/vol1/iss3/10

[5]. Duong, H. T., Ho, V. H., & Do, P. (2023). Fact-checking Vietnamese information using knowledge graph, datalog, and KG-BERT. *ACM Transactions on Asian and Low-Resource Language Information Processing*, *22*(10), 1-24. https://doi.org/10.1145/3624557

[6]. Minh, C. N., Hieu, N. H., Thuan, T. V., Hung, T. V., & Bang, V. Q. (2020). ReINTEL Challenge 2020: Vietnamese fake news detection using ensemble model with PhoBERT embeddings. In *Proceedings of the 7th International Workshop on Vietnamese Language and Speech Processing (VLSP)*.

[7]. Ninh, C. K., Vo, T. H., & Ninh, D. K. (2025). Combining Transformer, Bi-LSTM and CNN for efficient Vietnamese fake news detection. *UD-JST*, *23*(9B). https://doi.org/10.31130/ud-jst.2025.23(9B).496

[8]. Pham Dang, K., Thin, D. V., & Nguyen, N. L. T. (2023). Improving Vietnamese fake news detection based on contextual language model and handcrafted features. *Science & Technology Development Journal*, *26*(2), 2705-2712. https://doi.org/10.32508/stdj.v26i1.3927

[9]. Vinh, V. D., & Do, P. (2023). Detecting Vietnamese fake news. *CTU Journal of Innovation and Sustainable Development*, *15*(Special issue on ISDS), 39-46. https://doi.org/10.22144/ctujoisd.2023.033