HỘI THẢO NGHIÊN CỨU | Chuỗi Kiến trúc AI/ML

Các phương pháp Chunking trong hệ thống RAG

Phân tích so sánh và đề xuất phương pháp mới Hierarchical Semantic Chunking

BỐI CẢNH NGHIÊN CỨU

Thách thức xử lý Dữ liệu Doanh nghiệp Phi cấu trúc (Enterprise Unstructured Data)

Tài liệu PDF | Báo cáo DOC | Hợp đồng

CONTEXT & PROBLEM

Bối cảnh: RAG & Vai trò của Chunking

Fine-tuning vs. RAG

Fine-tuning tốn kém, khó cập nhật. RAG là giải pháp chuẩn cho dữ liệu doanh nghiệp (Enterprise Data) cần tính chính xác cao.

Quy trình RAG Pipeline

Retrieve (Truy hồi) → Augment (Tăng cường ngữ cảnh) → Generate (Sinh câu trả lời).

Chunking: Nút thắt cổ chai (Bottleneck)

Chunking là đầu vào của Retrieve. Chất lượng chunk quyết định độ chính xác toàn hệ thống ("Garbage In, Garbage Out").

Hệ quả của Chunking kém

Cắt ngang bảng biểu, mất tiêu đề Section, làm gãy ngữ cảnh tham chiếu, dẫn đến LLM bị "ảo giác" (Hallucination).

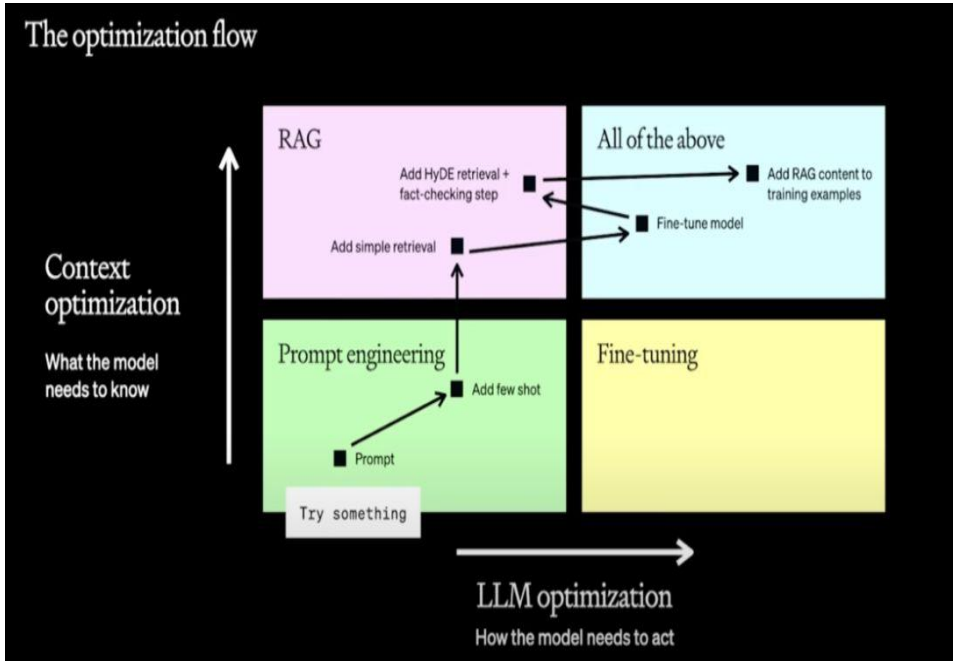

Lưu Trung Nguyện

Head of AI Solutions - SotaTek
Builder:

- NoteX AI Note Agent
- ChartX – AI Medical Documentation Platform
- SotaAgents Platform
- TranleaX AI Live Translator
- SocialFarm AI

Ex: Vingroup, Viettel, Topica, Techcombank

CHALLENGES & ISSUES

Vấn đề Chunking: Hạn chế & Thách thức Nâng cao

Hạn chế Cơ bản

Cắt ngang Bảng biểu

Fixed-size chunking thường cắt đôi bảng, làm mất header và merged cells, dẫn đến sai lệch dữ liệu nghiêm trọng.

Mất Ngữ cảnh Tiêu đề

Chunk bị tách rời khỏi tiêu đề cha (Parent Heading), khiến mô hình không hiểu chunk thuộc chủ đề nào.

Thách thức Nâng cao

Tham chiếu bị "Gãy"

Các tham chiếu như "xem Bảng 1", "theo Điều 5" không còn trỏ đến đúng nguồn khi chunk bị tách rời.

Thiếu Context Inference

LLM thiếu thông tin suy diễn logic từ metadata và cấu trúc tài liệu, dẫn đến ảo giác (hallucination).

Kết luận: Chunking truyền thống không đủ cho dữ liệu doanh nghiệp phức tạp.

ĐỀ XUẤT NGHIÊN CỨU

Mục tiêu & Giải pháp đề xuất

Mục tiêu nghiên cứu

Xây dựng phương pháp chunking tối ưu cho dữ liệu phi cấu trúc doanh nghiệp (PDF/DOC) nhằm nâng cao độ chính xác cho hệ thống Enterprise RAG.

Khoảng trống (Gaps) hiện tại

Mất cấu trúc: Chunking truyền thống làm gãy bảng biểu và mất ngữ cảnh phân cấp (Heading).

Gãy tham chiếu: Các chỉ dẫn "Xem Bảng 1", "Theo Điều 5" trở nên vô nghĩa khi tách rời.

Metadata phân mảnh: Thiếu thông tin ngữ cảnh (Context) cần thiết để LLM/Chatbot suy luận chính xác.

Giải pháp: 5-Layer HSC Methodology

Structure-Aware (Layers 1-2)

Phân tích Layout/DOM để bảo toàn cấu trúc phân cấp, nhận diện chính xác Bảng biểu và Header thay vì cắt text thuần túy.

Semantic Linking (Layer 3)

Giải quyết vấn đề "Gãy tham chiếu" bằng cách tạo liên kết ngữ nghĩa giữa Text và Bảng/Hình ảnh liên quan.

Contextual Assembly (Layer 4-5)

Tự động nhúng Metadata và Pre-context vào vector chunk cuối cùng, tối ưu hoá cho truy vấn của Chatbot.

Mục tiêu: Enterprise Agent với Vector-based RAG

Source: Proposed 5-Layer HSC Methodology (2025)

PHƯƠNG PHÁP ĐỀ XUẤT

Nguyên tắc Thiết kế HSC

Hierarchical Semantic Chunking

1. Modality-Aware Processing

Xử lý riêng biệt từng loại nội dung (Text, Table, Image, Header) với chiến lược tối ưu thay vì coi tất cả là văn bản thuần túy.

Xử lý Hình ảnh & Biểu đồ: Sau khi Layout Classification xác định là ảnh/biểu đồ, sử dụng Vision LLM để sinh mô tả văn bản chi tiết, biến dữ liệu visual thành searchable text.

2. Context-Preserving

Không bao giờ để mất ngữ cảnh thông qua cơ chế kế thừa (inheritance) từ tiêu đề cha và duy trì liên kết ngữ nghĩa giữa các thành phần.

3. Relationship-First

Xây dựng các liên kết ngữ nghĩa (semantic links) giữa các phần tử (như "xem Bảng 1", "Điều 5") trước khi thực hiện cắt nhỏ (chunking).

KIẾN TRÚC ĐỀ XUẤT (PROPOSED ARCHITECTURE)

Kiến trúc 5 Lớp HSC (Tổng quan)

Từ PDF phi cấu trúc đến Vector giàu ngữ cảnh (Hierarchical Semantic Chunking)

PDF

ĐẦU VÀO

Trích xuất & Liên kết

Trích xuất Layout
Thành phần, Tọa độ, Thứ tự

Phân loại Đa tầng
Loại Cấu trúc & Ngữ nghĩa

Liên kết Ngữ nghĩa
Tham chiếu, Phân cấp, Nối

Phân mảnh & Lắp ráp

Chunking theo Loại
Nhận diện Bảng, Cắt lai ghép

Luồng Ngữ cảnh

Lắp ráp Ngữ cảnh
Tiêu đề + Ngữ cảnh + Nội dung

Đầu ra Cuối cùng

Vector Index

Embedding đa chiều tích hợp ngữ cảnh cho Chatbot RAG

Toàn vẹn Cấu trúc (Structural Integrity)

• Tính nguyên vẹn của Bảng: Bảng là đơn vị logic; gộp bảng bị ngắt trang. • Tính phân cấp: Phần tử con kế thừa ngữ cảnh của cha (Điều/Khoản).

Bảo toàn Ngữ cảnh (Context Preservation)

• Xử lý Tham chiếu gãy: Link "Xem Bảng 1" tự động tiêm nội dung Bảng 1 vào chunk. • Sẵn sàng cho Vector: Metadata & ngữ cảnh được làm phẳng vào text cuối.

Hình 2: Quy trình 5 Lớp HSC cho Dữ liệu Doanh nghiệp

Chi tiết 4 chiến lược Semantic Linking

Reference Pattern

Tường minh

VÍ DỤ:
"Điều khoản thanh toán quy định tại Bảng 1"

Tạo liên kết trực tiếp từ Text sang Table 1

Proximity Linking

Ngầm định

VÍ DỤ:
Đoạn mô tả [A] nằm ngay trên Biểu đồ [B]

Tự động liên kết do vị trí liền kề (Adjacent)

Hierarchical Linking

Cấu trúc

VÍ DỤ:
Text và Table cùng thuộc mục "Điều 3"

Kế thừa chung ngữ cảnh của Section Header

Table Continuation

Liên trang

VÍ DỤ:
Bảng giá bị ngắt giữa Trang 5 và Trang 6

Gộp lại thành một bảng duy nhất (Merge)

TẦM QUAN TRỌNG

Layer 3 quyết định chất lượng Chunking: Thay vì cắt cô lập, hệ thống xây dựng graph ngữ nghĩa (Semantic Graph) trước. Kết quả là chunk cuối cùng luôn chứa đủ context từ các phần tử liên quan, dù chúng nằm rải rác trong tài liệu.

DEMO CASE STUDY | TRẠNG THÁI: CHƯA XỬ LÝ (RAW PDF)

Demo: PDF Văn bản Phức tạp - Trước xử lý HSC

Đặc điểm tài liệu

Cấu trúc phức tạp

Nhiều cột, bảng biểu lồng nhau, header/footer lặp lại.

Tham chiếu chéo

Chứa các câu như "Xem chi tiết tại Phụ lục A".

Bảng biểu ngắt trang

Bảng giá kéo dài qua 2-3 trang PDF.

THÁCH THỨC VỚI RAG THƯỜNG:

"Nếu chỉ cắt text theo độ dài cố định, LLM sẽ không hiểu bảng giá thuộc về điều khoản nào."

The burgeoning prioritization of wellness is translating into dollars spent. While Gen Zers and millennials make up just over a third (36 percent) of the adult population in the United States, they drive more than 41 percent of annual wellness spend. Compare that with consumers aged 58 and older: These consumers make up 35 percent of the population but only 28 percent of wellness spending. To be sure, older consumers still represent a meaningful opportunity for wellness players, especially in advanced markets with aging populations.

Gen Zers and millennials are not a homogenous group; there are nuanced differences in their perspectives on wellness. For example, although both groups rank sleep and health as their top two wellness priorities (but in a different order), Gen Zers give "better appearance" the number three slot, whereas millennials care more about mindfulness (Exhibit 1).

Exhibit 1

Gen Zers rank appearance among their top three wellness concerns, but mindfulness makes the cut for millennials.

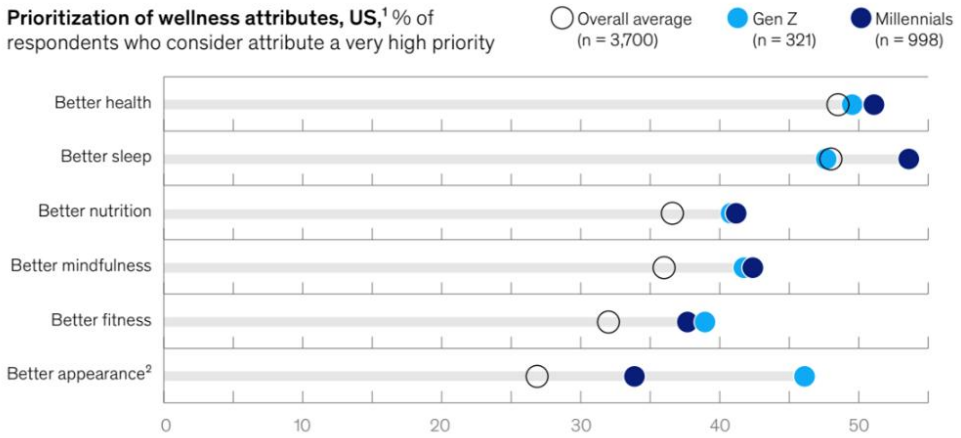

[1]Question: How high of a priority do you place on the following attributes?
[2]Through skin care, makeup, and other cosmetic enhancements.
Source: McKinsey Future of Wellness Survey, Nov 2024

McKinsey & Company

DEMO CASE STUDY | TRẠNG THÁI: ĐÃ XỬ LÝ (HSC OUTPUT)

Demo: Sau xử lý HSC - Semantic Graph + Context-Aware Chunks

Kết quả xử lý HSC

- **Semantic Graph**
  Các node Text và Table được liên kết qua Reference và Proximity link.
- **Merged Tables**
  Bảng ngắt trang đã được tự động nối lại thành một entity duy nhất.
- **Context Injection**
  Mỗi chunk đều chứa Header path: "Hợp đồng > Điều 5 > Bảng giá".

CẢI THIỆN RAG:

"Giờ đây khi user hỏi về 'giá dịch vụ', hệ thống truy xuất được chính xác Bảng giá cùng với Điều khoản áp dụng."

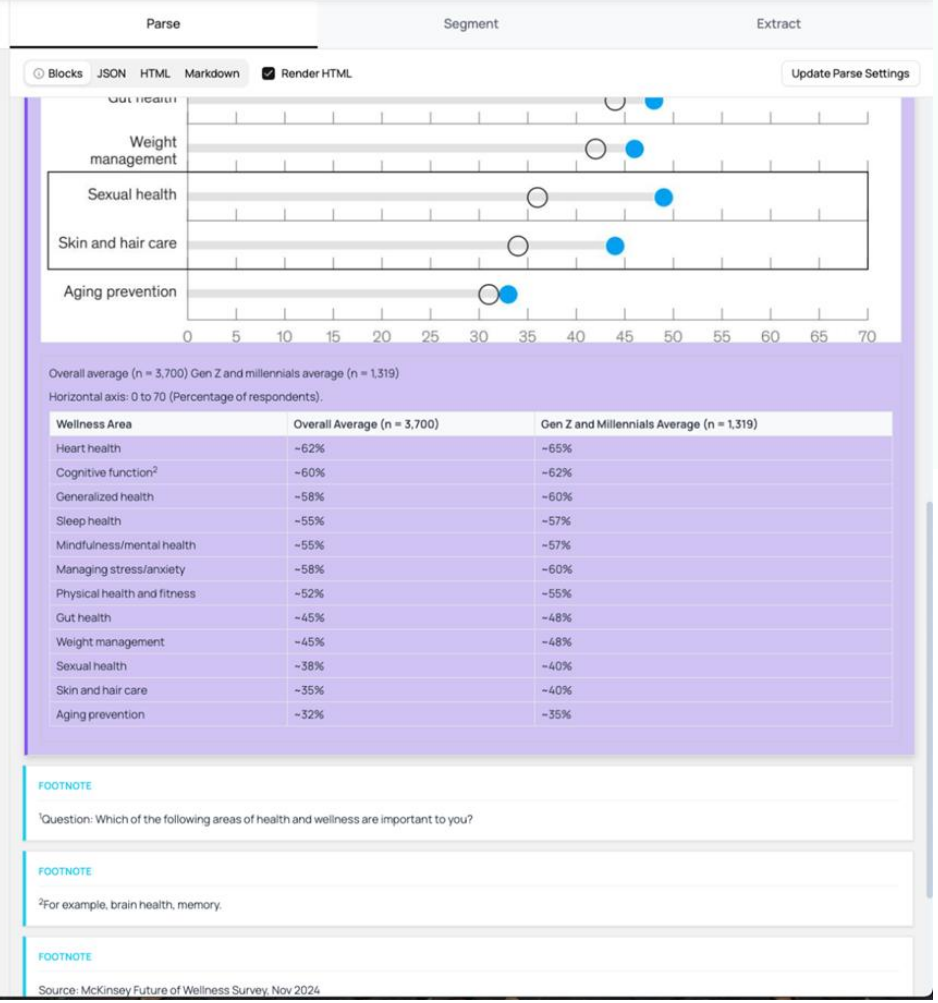

Wellness Area	Overall Average (n = 3,700)	Gen Z and Millennials Average (n = 1,319)
Heart health	~62%	~65%
Cognitive function[2]	~60%	~62%
Generalized health	~58%	~60%
Sleep health	~55%	~57%
Mindfulness/mental health	~55%	~57%
Managing stress/anxiety	~58%	~60%
Physical health and fitness	~52%	~55%
Gut health	~45%	~48%
Weight management	~45%	~48%
Sexual health	~38%	~40%
Skin and hair care	~35%	~40%
Aging prevention	~32%	~35%

DEMO CASE STUDY | TRẠNG THÁI: ĐÃ XỬ LÝ (HSC OUTPUT)

Demo: Sau xử lý HSC - Semantic Graph + Context-Aware Chunks

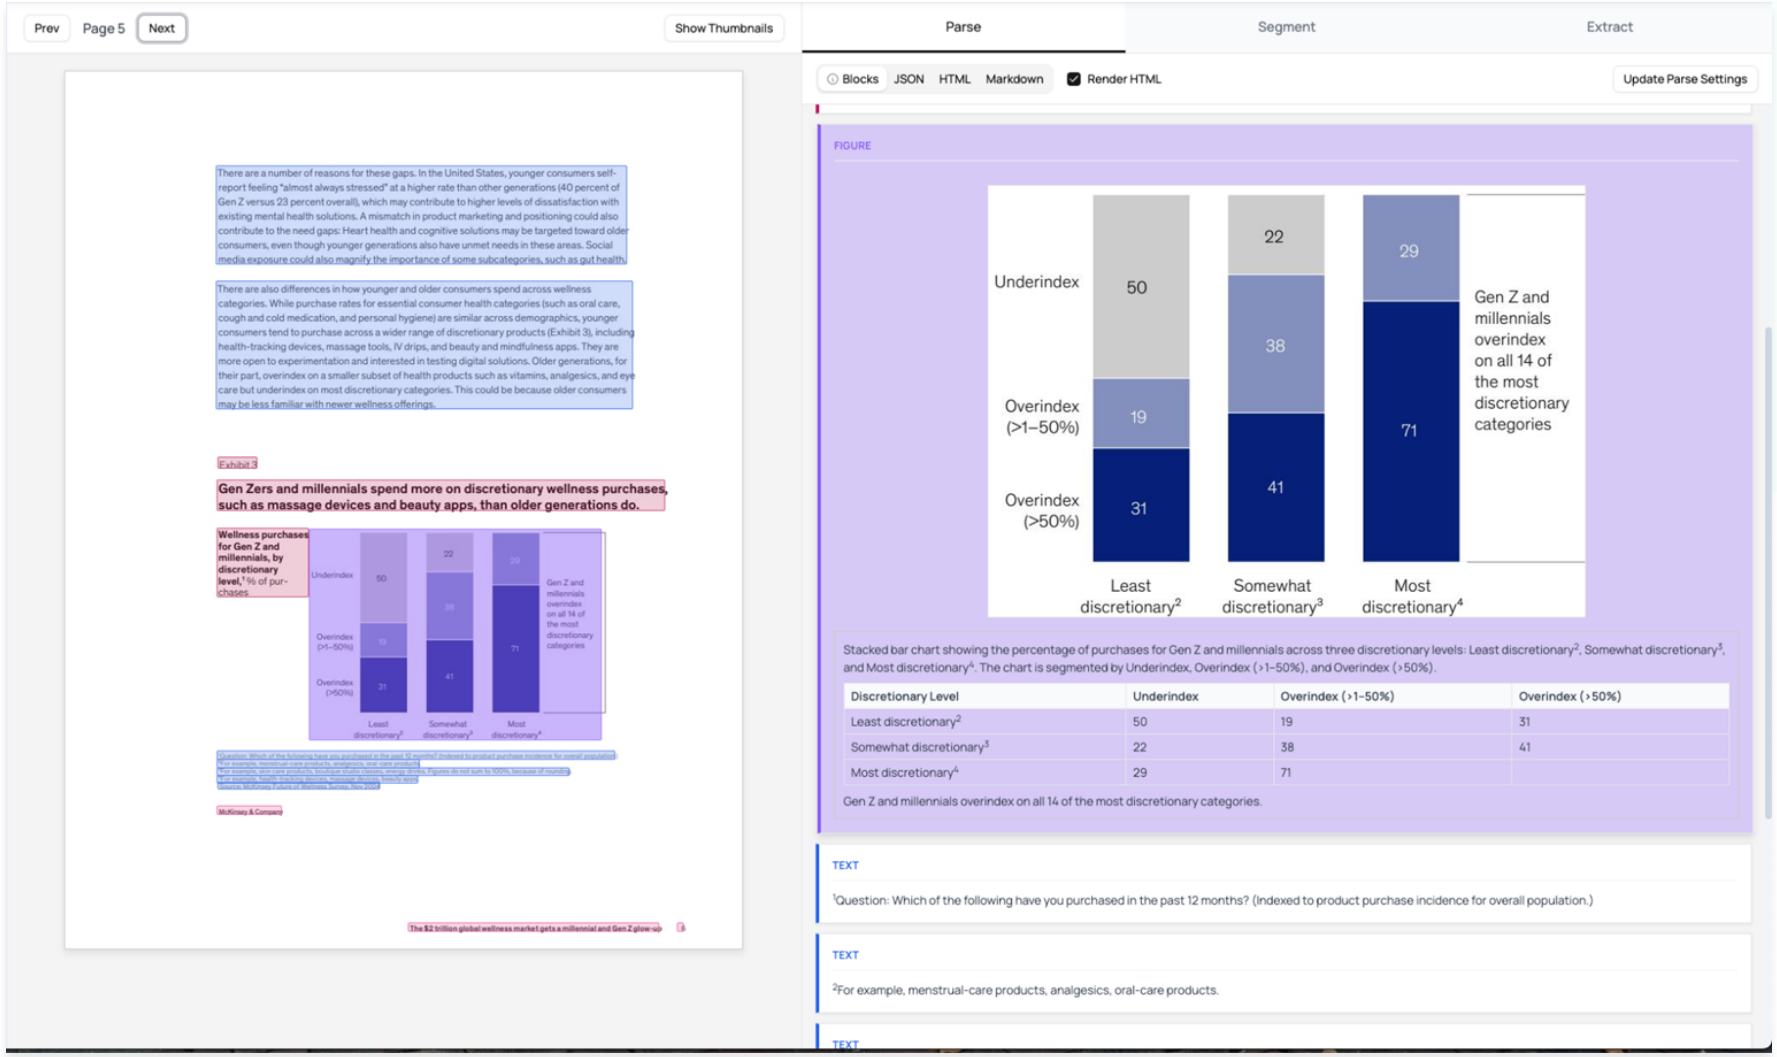

DEMO COMPARISON | PERFORMANCE EVALUATION

So sánh: Chunking Truyền thống vs HSC

Chunking Truyền thống

Fixed-size / Recursive

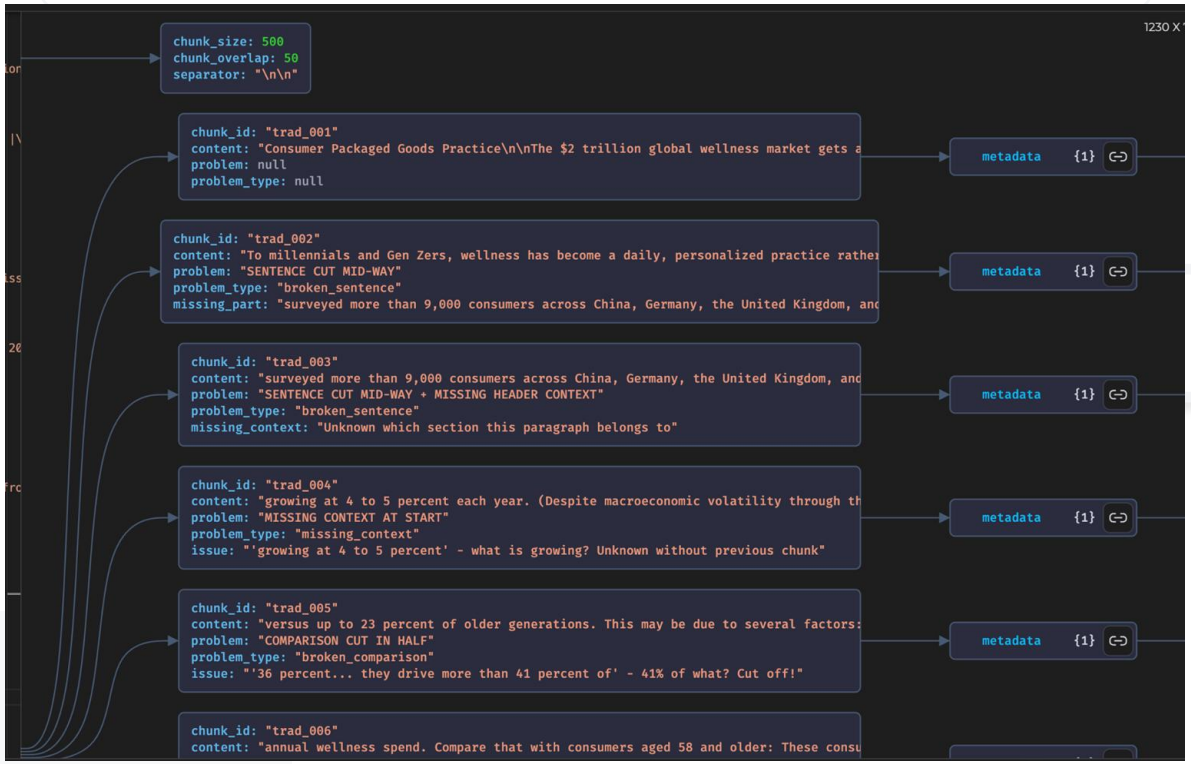

Phương pháp HSC

Semantic & Structure Aware

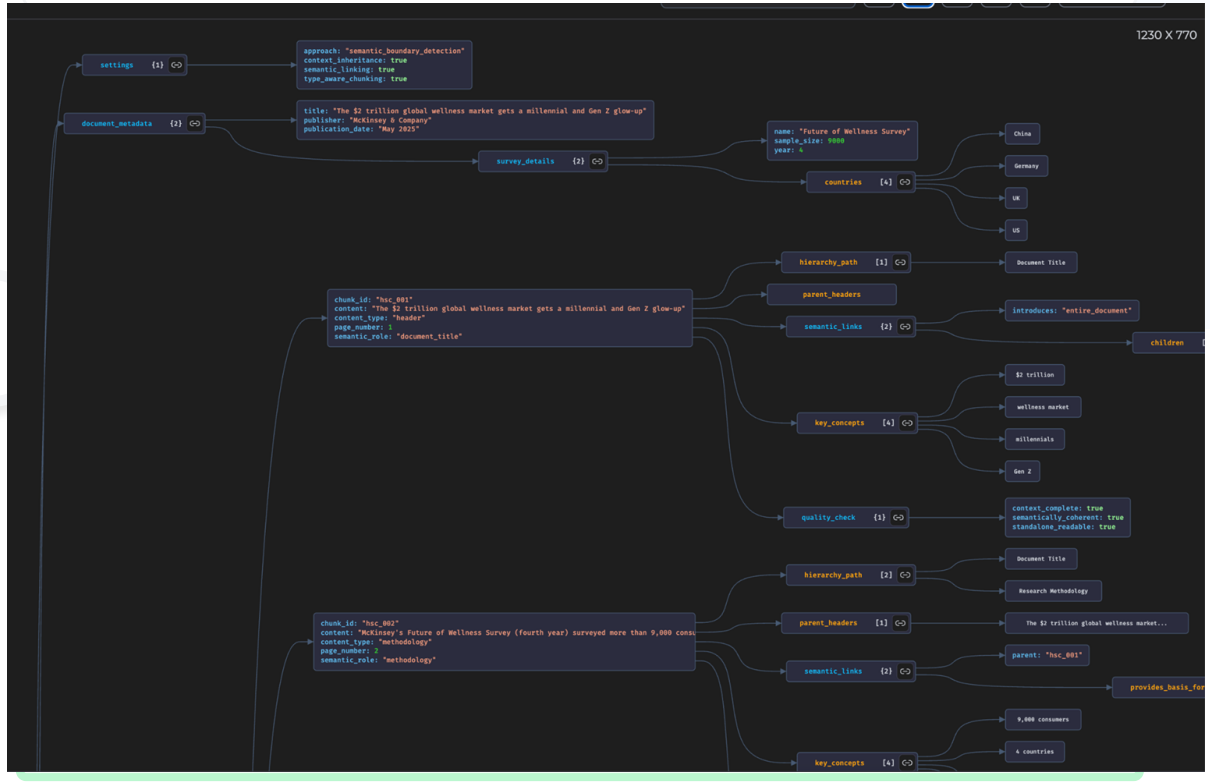

Conclusion: HSC cải thiện lớn độ chính xác truy xuất - cần nghiên cứu sâu hơn để đo benchmark

ỨNG DỤNG

Hiệu quả Triển khai Sản phẩm AI Thực tế

Case Studies 2025

NoteX AI Meeting Agent

Intelligent Meeting Transcription & Analysis

Topic-based Chunking Strategy

27% ↑

SUMMARY USEFULNESS

SotaAgents Platform

Enterprise Business AI Agents

Multi-modal Chunking Pipeline

32% ↑

CROSS-DOC ACCURACY

53% ↑

TABLE QUERY SUCCESS

Kết luận & Giá trị cốt lõi

Phương pháp Hierarchical Semantic Chunking (HSC-SN) giải quyết triệt để các hạn chế về ngữ cảnh và cấu trúc trong RAG. Bằng cách kết hợp xử lý đa phương thức (Multimodal) và chuẩn hóa dữ liệu (Schema Normalization), hệ thống đạt được sự cân bằng tối ưu giữa độ chính xác ngữ nghĩa và khả năng truy vấn dữ liệu có cấu trúc.

KẾ HOẠCH TIẾP THEO

- Benchmark vs Late Chunking (v2)
- Mở rộng Schema Catalog cho Finance
- Open Source module HSC-Core

TỔNG KẾT NGHIÊN CỨU

Kết luận & Hướng nghiên cứu

Hạn chế của Chunking Hiện tại

Các phương pháp truyền thống thất bại trong việc xử lý bảng biểu phức tạp, mất ngữ cảnh của Điều/Khoản và gãy tham chiếu trong tài liệu doanh nghiệp.

Đóng góp: HSC 5-Layer

Đề xuất kiến trúc 5 lớp tối ưu cho RAG doanh nghiệp: bảo toàn cấu trúc bảng, kế thừa ngữ cảnh phân cấp và tích hợp metadata pre-context tự động.

Đổi mới: Semantic Linking

Thay vì cắt cô lập, hệ thống xây dựng đồ thị ngữ nghĩa (Semantic Graph) trước. Giải quyết triệt để vấn đề "tham chiếu gãy" trong tài liệu dài.

Hướng phát triển Enterprise RAG

Triển khai thực tế (Production RAG) với đánh giá A/B testing trên câu hỏi nghiệp vụ thực tế và tối ưu độ trễ cho phản hồi thời gian thực.

> *"Chunking thông minh là chìa khóa để hệ thống RAG doanh nghiệp trả lời chính xác như tư vấn chuyên gia."*